

의료 지식 그래프와 임상 진료지침을 활용한 GraphRAG 기반 의료 질의응답 시스템 개발



202255536 김채은 chloe107@pusan.ac.kr

202255560 신우숨 gee0209@pusan.ac.kr

202355647 이정현 junghyeon4795@gmail.com

지도교수: 송길태

목 차

1. 서론.....	1
1.1. 연구 배경.....	1
1.2. 문제 정의.....	1
1.3. 연구 목표.....	1
2. 연구 배경.....	1
2.1. 표준 의료 용어체계.....	1
2.2. Dense Retrieval, Sparse Retrieval과 Hybrid Search.....	3
2.3. RAG와 GraphRAG.....	4
2.4. 임상 진료지침.....	5
3. 연구 내용.....	7
3.1. 전체 처리 흐름.....	7
3.2. 의료 데이터 및 검색 기반 구축.....	10
3.2.1. 표준 의료 용어 데이터 전처리.....	10
3.2.2. 의료 지식 그래프 구축 및 Neo4j 적재.....	12
3.2.3. 의료 개념 검색 데이터베이스 및 인덱스 구축.....	15
3.2.4. 임상 진료지침 검색 데이터 구축.....	17
3.3. 핵심 기능 구현.....	20
3.3.1. 의료 표현 추출 및 Entity Linking.....	20
3.3.2. 의도 기반 지식 그래프 탐색.....	28
3.3.3. Graph Context 생성.....	33
3.3.4. 임상 진료지침 검색 및 Context 구성.....	38

3.3.5.	근거 기반 답변 생성	42
3.4.	웹서비스 구현	48
3.4.1.	사용자 인터페이스	48
3.4.2.	답변 근거 표시	50
3.5.	시스템 설계	53
3.5.1.	시스템 구조	53
3.5.2.	데이터베이스	54
3.5.3.	REST API	55
3.5.4.	실행 환경	56
4.	연구 결과 분석 및 평가	57
4.1.	정량 평가	57
4.1.1.	평가 방법	57
4.1.2.	전체 성능	59
4.1.3.	문항 유형별 성능	60
4.1.4.	질환 및 문항 유형별 정확도 비교	61
4.2.	사례 분석	62
4.2.1.	T2DM 사례	63
4.2.2.	HTN 사례	64
4.2.3.	CKD 사례	67
4.2.4.	HF 사례	69
5.	결론 및 향후 연구 방향	72
5.1.	결론	72
5.1.1.	의료 지식 검색 및 근거 기반 답변 생성	72
5.1.2.	답변 근거를 제공하는 웹서비스 구현	72

5.1.3.	의료 질의응답 성능 평가 결과.....	72
5.2.	향후 연구 방향.....	72
5.2.1.	임상 진료지침 범위 확대	72
5.2.2.	평가 데이터 확대 및 균형화	73
5.2.3.	고성능 LLM 적용.....	73
6.	참고 문헌.....	73

1. 서론

1.1. 연구 배경

대규모 언어 모델(LLM)의 발전으로 의료 질의응답 시스템의 활용 가능성이 확대되고 있으나, 의료 분야에서는 답변의 정확성과 함께 이를 뒷받침하는 근거 정보의 제공이 중요하다. 기존 LLM과 문서 검색 기반 RAG의 한계를 보완하기 위해, 본 연구에서는 의료 지식 그래프와 임상 진료지침(Clinical Guideline) 검색을 결합한 MedicalQA 의료 질의응답 시스템을 구축하였다.

1.2. 문제 정의

LLM을 단독으로 사용할 경우 학습된 지식에 의존하기 때문에 부정확한 답변이나 근거가 부족한 응답이 생성될 수 있다. 또한 일반적인 RAG는 텍스트 유사도 중심으로 정보를 검색하므로 의료 개념 간의 구조적 관계를 충분히 활용하기 어렵다. 따라서 사용자 질의의 의료 개념을 정확히 식별하고, 지식 그래프의 관계 정보와 임상 진료지침을 함께 검색하여 답변 생성에 활용하는 방법이 필요하다.

1.3. 연구 목표

본 연구의 목표는 GraphRAG 기반 의료 지식 그래프 검색과 임상 진료지침 검색을 결합한 MedicalQA 시스템을 구축하고 그 효과를 평가하는 것이다. 이를 위해 Entity Linking, Neo4j 기반 그래프 탐색, Qdrant 기반 진료지침 검색 및 Gemma 기반 답변 생성 파이프라인을 구현하고, React와 FastAPI를 이용한 웹서비스를 개발하였다. 마지막으로 MedQA 문항을 이용하여 Gemma4-only와 MedicalQA의 정확도를 비교하여 검색 기반 의료 정보 활용에 따른 성능 차이를 분석하였다.

본 연구의 주요 대상 질환은 Type 2 Diabetes Mellitus (T2DM), Hypertension (HTN), Chronic Kidney Disease (CKD), Heart Failure (HF), Chronic Obstructive Pulmonary Disease (COPD)이며, 이하 각각 T2DM, HTN, CKD, HF, COPD로 표기한다.

2. 연구 배경

2.1. 표준 의료 용어체계

의료 분야에서는 질병, 증상, 약물, 검사 등 다양한 의료 개념이 서로 복잡한 관계를 형

성하고 있다. 이러한 정보를 일관된 형태로 표현하고 시스템 간에 공유하기 위해 표준화된 의료 용어체계가 활용된다. 본 연구에서는 의료 개념과 개념 간 관계를 구조화하기 위해 SNOMED CT, RxNorm, LOINC를 활용하였다.

SNOMED CT는 전자의무기록을 비롯한 의료정보시스템에서 임상 정보를 일관되고 구조화된 형태로 표현하기 위한 표준 임상 용어체계이다. 주요 구성 요소는 의료 개념을 나타내는 Concept, 각 Concept의 공식 명칭과 동의어를 제공하는 Description, Concept 사이의 의미적 연결을 나타내는 Relationship으로 구성된다. 이를 통해 질병, 임상 소견, 시술, 신체 구조 등 다양한 의료 개념과 개념 간 관계를 표현할 수 있다. 본 연구에서는 질환과 증상, 검사 결과 및 기타 임상 개념을 표현하고, 이들 사이의 관계를 지식 그래프로 구성하는 데 활용하였다.

RxNorm은 임상 의약품의 명칭을 표준화하고 동일한 의약품에 대한 다양한 표현을 연결하기 위한 의약품 용어체계이다. 약물의 활성 성분, 함량, 제형 및 상품명 등에 관한 정보를 표준 Concept으로 관리하며, 각 용어에는 해당 표현의 유형을 나타내는 TTY(Term Type) 정보와 Concept 사이의 관계 정보가 함께 제공된다. 이를 통해 약물이 어떤 성분이나 제형으로 구성되는지, 특정 상품명과 어떤 표준 약물 Concept이 연결되는지 등을 표현할 수 있다. 본 연구에서는 질환과 치료 약물 사이의 관계를 구성하고, SNOMED CT 기반 질환 Concept과 RxNorm의 약물 정보를 연결하는 데 활용하였다.

LOINC는 임상검사 및 관찰 항목을 표준화하기 위한 의료 용어체계이다. LOINC의 검사 항목은 검사 대상 성분을 나타내는 Component, 측정 특성을 나타내는 Property, 측정 시점을 나타내는 Time, 검체 또는 시스템을 나타내는 System, 결과 표현 방식을 나타내는 Scale, 측정 방법을 나타내는 Method의 주요 축을 이용하여 구조적으로 표현된다. 본 연구에서는 질환 및 약물과 관련된 검사 정보를 표현하고, 이러한 검사 및 구성 요소 사이의 관계를 의료 지식 그래프에 연결하는 데 활용하였다.

세 용어체계의 주요 역할은 표 1과 같이 정리할 수 있다.

표 1. 본 연구에서 활용한 표준 의료 용어체계

표준 의료 용어체계	주요 정보	본 연구에서의 활용
SNOMED CT	질병, 증상, 임상 소견, 시술 등	의료 개념 및 개념 간 관계 구성
RxNorm	약물 성분 및 의약품 정보	약물 개념 및 질환-약물 관계 구성
LOINC	임상검사 및 관찰 항목	검사 개념 및 검사 관련 관계 구성

본 연구에서는 서로 다른 의료 용어체계를 공통된 의료 개념 구조로 관리하고, 각 온톨로지 내부의 관계뿐 아니라 질병·약물·검사 사이의 교차 온톨로지 관계를 연결하여 Neo4j 기반 의료 지식 그래프로 구성하였다. 이를 통해 단순한 키워드 일치가 아니라 질병, 약물, 검사 등 서로 다른 종류의 의료 정보를 관계 중심으로 탐색하고 활용할 수 있도록 하였다.

2.2. Dense Retrieval, Sparse Retrieval과 Hybrid Search

표준 의료 개념을 검색할 때에는 사용자의 표현과 의료 용어가 정확하게 일치하는 경우뿐만 아니라, 서로 다른 표현이지만 의미적으로 동일하거나 유사한 경우도 함께 고려할 필요가 있다. 이러한 정보 검색 방식은 크게 의미적 유사도를 이용하는 Dense Retrieval과 단어의 일치 정도를 이용하는 Sparse Retrieval로 구분할 수 있다.

Dense Retrieval은 텍스트를 고차원의 벡터(Embedding)로 변환하고 벡터 간 유사도를 계산하여 의미적으로 가까운 항목을 검색하는 방식이다. 따라서 질의와 검색 대상의 표현이 완전히 일치하지 않더라도 의미가 유사하면 관련 항목을 검색할 수 있다는 장점이 있다. 예를 들어 동일한 질환이 동의어나 서로 다른 자연어 표현으로 입력되는 경우에도 관련 의료 개념을 검색하는 데 활용할 수 있다.

반면 Sparse Retrieval은 BM25와 같은 통계 기반 검색 알고리즘을 이용하여 질의와 검색 대상에 공통으로 등장하는 단어의 일치 정도를 기준으로 관련성을 계산한다[1]. 질환명, 약물명, 검사명 및 약어와 같이 정확한 용어가 입력된 경우 효과적으로 검색할 수 있지만, 질의와 검색 대상의 표현이 서로 다른 경우에는 의미적으로 관련된 개념을 충분히 반영하기 어려울 수 있다.

두 방식은 서로 다른 검색 특성을 가지므로, 이를 결합한 Hybrid Search를 통해 상호 보완적으로 활용할 수 있다. Hybrid Search는 Dense Retrieval과 Sparse Retrieval을 각각 수행한 뒤 두 검색 결과의 점수를 결합하여 최종 후보의 순위를 결정한다. 이를 통해 의미적으로 유사한 표현을 탐색하는 Dense Retrieval의 장점과 정확한 용어 일치를 반영하는 Sparse Retrieval의 장점을 함께 활용할 수 있다.

표 2. Dense Retrieval과 Sparse Retrieval 비교

구분	Dense Retrieval	Sparse Retrieval
검색 기준	벡터 간 의미적 유사도	키워드(단어) 일치 정도
대표 방식	Embedding 기반 벡터 검색	BM25
강점	동의를 및 서로 다른 표현의 검색에 유리	정확한 용어 및 약어 일치에 유리
한계	정확한 키워드 일치의 중요도를 충분히 반영하지 못할 수 있음	표현이 다른 경우 관련 개념이 검색되지 않을 수 있음

본 연구에서는 표준 의료 개념 검색에 두 방식의 장점을 함께 활용하기 위해 Dense Retrieval 기반의 Embedding Search와 Sparse Retrieval 기반의 BM25 Keyword Search를 결합한 Hybrid Search를 적용하였다. 구체적인 검색 데이터 구축과 검색 결과 결합 방법은 3장에서 설명한다.

2.3. RAG와 GraphRAG

대규모 언어 모델은 학습된 지식을 기반으로 자연스러운 답변을 생성할 수 있지만, 질문에 필요한 외부 정보를 직접 조회하지 않는 경우 모델 내부에 학습된 정보에 의존하여 답변을 생성하게 된다. 이러한 한계를 보완하기 위한 방법 중 하나가 검색 증강 생성(Retrieval-Augmented Generation, RAG)이다.

RAG는 사용자의 질문과 관련된 외부 정보를 검색한 후, 검색 결과를 사용자 질문과 함께 LLM에 제공하여 답변을 생성하는 방식이다. 이를 통해 모델이 사전에 학습한 정보뿐만 아니라 검색을 통해 확보한 외부 정보를 답변 생성 과정에서 함께 활용할 수 있다.

그러나 일반적인 RAG는 주로 문서나 텍스트 단위의 유사도 검색을 기반으로 하기 때문에, 질병과 약물, 검사, 임상 소견과 같이 서로 연결된 의료 개념 사이의 구조적인 관계를 직접 탐색하고 활용하는 데에는 한계가 있다.

GraphRAG는 이러한 한계를 보완하기 위해 그래프 구조의 정보를 검색 및 답변 생성 과정에 활용하는 방식이다. 그래프는 Node와 Edge를 이용하여 개체와 개체 사이의 관계를 명시적으로 표현할 수 있으므로, 단순히 관련 텍스트를 검색하는 것을 넘어 서로 연결된 개념과 관계 정보를 함께 탐색하고 활용할 수 있다.

Han et al.은 GraphRAG의 전체 구조를 Query Processor, Data Source, Retriever, Organizer, Generator의 다섯 가지 핵심 구성요소로 구분하였다[2]. Query Processor는 사용자의 질의를 검색에 적합한 형태로 처리하고, Data Source는 검색에 활용할 그래프 형태의 외부 지식을 제공한다. Retriever는 질의를 기반으로 관련 그래프 정보를 검색하며, Organizer는 검색된 정보를 답변 생성에 활용할 수 있는 형태로 정리한다. Generator는 사용자 질의와 정리된 검색 정보를 이용하여 최종 답변을 생성한다.

표 3. GraphRAG의 주요 구성요소

구성요소	역할
Query Processor	사용자 질의를 검색에 적합한 형태로 처리
Data Source	그래프 형태의 외부 지식 제공
Retriever	질의와 관련된 그래프 정보 검색
Organizer	검색 결과를 답변 생성에 활용할 수 있는 형태로 정리
Generator	질의와 검색·정제된 정보를 이용하여 최종 답변 생성

본 연구의 MedicalQA도 이러한 GraphRAG의 처리 구조를 참고하여 의료 질의응답 파이프라인을 구성하였다. 사용자 질문의 재작성과 의료 표현 추출을 통해 검색에 필요한 정보를 식별하고, SNOMED CT, RxNorm, LOINC를 기반으로 구축한 Neo4j 의료 지식 그래프를 외부 지식으로 활용하였다. 이후 Entity Linking을 통해 선택된 의료 Concept을 시작점으로 지식 그래프를 탐색하고, 탐색된 의료 개념과 관계를 자연어 형태의 Graph Context로 변환하여 최종 답변 생성에 활용하였다.

즉, 본 연구에서 GraphRAG는 질병, 증상, 약물 및 검사와 같은 의료 개념 간의 구조적인 관계를 검색하고, 검색된 관계 정보를 LLM의 답변 생성에 활용하기 위한 방법으로 사용하였다. 구체적인 의료 지식 그래프 구축, 의료 개념 검색, 지식 그래프 탐색 및 Graph Context 생성 과정은 3장에서 설명한다.

2.4. 임상 진료지침

의료 질의응답에서는 질병이나 약물 사이의 관계를 파악하는 것뿐만 아니라 실제 진료 과정에서 활용되는 치료 및 관리 기준을 함께 고려하는 것이 중요하다. 의료 지식 그래프는 의료 개념과 개념 사이의 구조적 관계를 제공할 수 있지만, 특정 환자의 상태에 따

른 치료 권고나 관리 기준과 같은 임상적 정보를 모두 표현하기에는 한계가 있다.

임상 진료지침은 질환의 진단, 치료 및 관리에 관한 권고사항을 체계적으로 정리한 자료로, 의료적 판단을 위한 중요한 근거로 활용된다. 본 연구에서는 주요 대상 질환과 관련된 WHO와 NICE의 임상 진료지침을 수집하여 의료 질의응답에 활용하였다.

본 연구에서 두 종류의 검색 정보는 서로 다른 역할을 수행한다. 지식 그래프는 질병, 증상, 약물, 검사 등 의료 개념 사이의 관계를 구조적으로 제공하고, 임상 진료지침은 치료 및 관리와 관련된 임상적 권고 정보를 제공한다. 따라서 두 정보를 함께 활용함으로써 하나의 정보원만 사용하는 경우보다 다양한 형태의 의료 근거를 답변 생성 과정에 제공할 수 있도록 하였다.

구체적인 지식 그래프 검색과 임상 진료지침 검색 과정 및 답변 생성 방법은 다음 장에서 설명한다.

3. 연구 내용

3.1. 전체 처리 흐름

본 연구에서 구현한 MedicalQA는 사용자의 의료 질문을 입력받아 GraphRAG 기반 지식 그래프 검색과 임상 진료지침 검색을 수행하고, 검색된 정보를 활용하여 대규모 언어 모델이 답변을 생성하는 구조로 구성하였다. 전체 질의응답 처리 흐름은 그림 1과 같다.




그림 1. MedicalQA 의료 질의응답 처리 흐름

사용자의 질문은 다음과 같은 과정으로 처리된다.


1. 질문 처리

사용자의 의료 질문을 입력받고, 이전 대화가 존재하는 후속 질문의 경우 대화 이력을 이용하여 현재 질문을 독립적으로 이해할 수 있는 형태로 재작성(Question Rewrite)한다.

대화형 질의응답에서는 사용자가 “그럼 그건 어떻게 치료해?”와 같이 이전 대화의 내용을 지시대명사로 참조하거나 일부 정보를 생략하여 질문할 수 있다. 이러한 질문을 그대로 Mention Detection이나 Guideline Search에 사용할 경우 현재 질문만으로는 검색 대상이 명확하지 않아 필요한 의료 개념이나 임상 진료지침을 검색하기 어려울 수 있다. 이에 이전 대화 이력을 참고하여 지시대명사와 생략된 표현을 명확하게 보완하면서도, 원래 질문의 의도와 범위는 유지하도록 질문을 재작성하였다.

질문 재작성 시에는 모호한 참조가 존재하는 경우 최근 대화 내용을 우선적으로 고려하고, 기존 질문에 없던 새로운 의료 정보를 임의로 추가하지 않도록 제한하였다. 또한 현재 질문 자체만으로 충분히 이해할 수 있는 경우에는 불필요하게 내용을 변경하지 않도록 하였다. 이렇게 생성된 재작성 질문은 이후 Mention Detection, 의료 개념 검색, 임상 진료지침 검색 및 최종 답변 생성 과정의 입력으로 사용된다.

예를 들어 이전 대화에서 COPD의 합병증에 대해 질문한 뒤 “How should those complications be monitored?”와 같이 후속 질문을 입력한 경우, 이전 대화의 문맥을 반영하여 COPD 관련 합병증의 모니터링을 묻는 독립적인 질문으로 재작성된다. 그림 2는 실제 시스템에서 이러한 질문 재작성 과정이 수행된 결과를 보여준다.



Original Question: How should those complications be monitored? medicalQA.js:22

Rewritten Question: How should the complications associated with Chronic Obstructive Pulmonary Disease (COPD), such as pulmonary hypertension, respiratory issues, systemic/multi-organ complications, and structural changes, be monitored? medicalQA.js:23

그림 2. 대화 이력을 이용한 후속 질문 재작성 예시

2. 의료 개념 및 지식 그래프 검색

질문에서 의료 관련 표현을 추출하고 관련 의료 개념을 검색하여 Concept Set을 구성한다. 이후 선택된 의료 개념을 기반으로 Neo4j 지식 그래프를 탐색하고, 답변 생성에 활용할 Graph Context를 생성한다.

3. 임상 진료지침 검색

사용자 질문을 임베딩한 후 Qdrant에 저장된 임상 진료지침에서 관련 내용을 검색한다. 상위 검색 결과를 정리하여 답변 생성에 활용할 Guideline Context를 구성한다.

4. 근거 기반 답변 생성

사용자 질문과 Graph Context, Guideline Context를 Gemma 모델에 함께 입력하여 최종 의료 답변을 생성한다.

5. 결과 제공

생성된 답변과 한국어 번역 결과, 검색된 지식 그래프 및 임상 진료지침 정보를 웹서비스로 전달한다. 사용자는 이를 통해 답변과 관련 근거를 함께 확인할 수 있다.

이상의 과정은 실제 파이프라인에서 질문 재작성 → Mention Detection → Hybrid Search → Concept Set 생성 → 지식 그래프 탐색 및 Graph Context 생성 → Guideline Search 및 Guideline Context 생성 → 답변 생성 Prompt 구성 → LLM 답변 생성 → 한국어 번역 → 최종 응답 반환의 순서로 실행된다. 각 단계에서 생성된 결과는 다음 단계의 입력으로 전달되며, 최종적으로 생성된 답변과 번역 결과, 지식 그래프 및 임상 진료지침 근거 정보가 웹서비스에 반환된다.

의료 개념 검색, 지식 그래프 탐색, 임상 진료지침 검색 및 답변 생성의 세부 구현 방법은 다음 절에서 설명한다.

3.2. 의료 데이터 및 검색 기반 구축

MedicalQA에서 의료 개념 및 임상 진료지침을 검색하기 위해서는 원본 의료 데이터를 검색 가능한 형태로 구축하는 과정이 필요하다. 본 연구에서는 SNOMED CT, RxNorm, LOINC의 표준 의료 용어 데이터를 공통 구조로 전처리하고, 이를 기반으로 의료 개념 검색을 위한 벡터 데이터베이스와 키워드 검색 인덱스를 구축하였다. 또한 임상 진료지침을 별도의 검색 데이터로 구축하여 이후 질의응답 과정에서 근거 정보로 활용하였다.

3.2.1. 표준 의료 용어 데이터 전처리

본 연구에서는 의료 개념 검색과 지식 그래프 탐색을 위해 SNOMED CT, RxNorm, LOINC의 데이터를 활용하였다. 세 의료 용어체계는 서로 다른 파일 구조와 용어 표현 방식을 사용하므로, 하나의 검색 대상으로 활용하기 위해 공통된 형태로 전처리하였다.

의료 개념 검색에서 공통적으로 사용할 수 있도록 각 데이터의 주요 정보를 conceptId, term, descriptionType, ontology 구조로 통일하였다. 이때 conceptId는 의료 개념의 고유 식별자, term은 실제 의료 용어 표현, descriptionType은 해당 표현의 유형, ontology는 SNOMED CT, RxNorm, LOINC 중 출처를 나타낸다.

SNOMED CT에서는 활성 상태의 Description만을 사용하고 중복 및 결측 데이터를 제거하였다. 또한 SNOMED CT에는 질병·임상 소견·시술·신체 구조뿐 아니라 검색 시작점으로 활용하기 어려운 속성 및 관리용 개념도 포함되어 있으므로, semantic tag를 기준으로 실

제 의료 질의와 관련성이 높은 임상 개념을 중심으로 선별하였다. 그 결과 총 **1,249,608**개의 Description을 검색 대상으로 구성하였다.

RxNorm에서는 약물 검색에 필요한 Concept ID와 약물명 및 용어 유형 정보를 추출하였다. 여러 출처 가운데 RxNorm의 표준 약물 정보를 중심으로 사용하고, 실제 처방 및 의료 질의에 활용도가 낮은 용어 유형과 중복 표현을 제거하였다. 최종적으로 **129,472**개의 Description을 구성하였다.

LOINC에서는 활성 상태의 검사 및 관찰 항목을 대상으로 하였으며, 문서·행정·설문 등 실제 검사 및 측정과 직접적인 관련이 낮은 항목은 제외하였다. 하나의 검사에 존재하는 공식 명칭과 축약명, 표시명 등의 여러 표현을 각각 검색 가능한 Description 형태로 변환하여 최종적으로 **211,858**개의 Description을 구성하였다.

전처리를 통해 세 의료 용어체계를 동일한 구조의 검색 대상으로 통합하였으며, 최종적으로 총 **1,590,938**개의 의료 Description을 확보하였다. 이 데이터는 이후 Embedding 기반 검색과 BM25 기반 Keyword Search의 공통 검색 대상으로 활용하였다.

표 4. 표준 의료 용어 데이터 전처리 결과

의료 용어체계	주요 전처리 내용	최종 Description 수
SNOMED CT	활성 데이터 선별, 중복·결측 제거, 임상 개념 중심 semantic tag 필터링	1,249,608
RxNorm	표준 약물 정보 선별, 검색에 불필요한 용어 유형 및 중복 제거	129,472
LOINC	활성 검사·관찰 항목 선별, 비검사성 항목 제거, 여러 명칭을 Description 형태로 변환	211,858
합계		1,590,938

conceptid	descriptionType	term	ontology	semantic_tag
126813005	Synonym	Neoplasm of anterior aspect of epiglottis	SNOMED	disorder
126814004	Synonym	Neoplasm of junctional region of epiglottis	SNOMED	disorder
126815003	Synonym	Neoplasm of lateral wall of oropharynx	SNOMED	disorder
126816002	Synonym	Neoplasm of posterior wall of oropharynx	SNOMED	disorder
126817006	Synonym	Neoplasm of esophagus	SNOMED	disorder

(a) SNOMED CT

conceptId	term	ontology	descriptionType
38	Parlodel	RXNORM	Brand Name
44	mesna	RXNORM	Ingredient
61	beta-alanine	RXNORM	Ingredient
73	docosahexaenoate	RXNORM	Ingredient
74	4-aminobenzoic acid	RXNORM	Ingredient

(a) RxNorm

conceptId	term	descriptionType	ontology
10000-8	R wave duration in lead AVR	FSN	LOINC
10000-8	R wave dur L-AVR	Synonym	LOINC
10001-6	R wave duration in lead I	FSN	LOINC
10001-6	R wave dur L-I	Synonym	LOINC
100019-9	ALK gene mutations found [Identifier] in Blood...	FSN	LOINC

(a) LOINC

그림 3. 온톨로지별 전처리 완료 데이터 예시 (상위 5행)

※ RxNorm은 SNOMED CT·LOINC와 달리 FSN/Synonym 이분 체계 대신, 약물의 성분·상품명·처방단위 등을 세분화한 TTY 체계를 descriptionType에 사용하였다.

※ semantic_tag는 SNOMED CT에만 존재하는 컬럼으로, Neo4j 지식 그래프 구축 단계에서 활용된다.

3.2.2. 의료 지식 그래프 구축 및 Neo4j 적재

MedicalQA에서 의료 개념 간의 구조적인 관계를 탐색하기 위해 SNOMED CT, RxNorm, LOINC의 의료 개념과 관계 정보를 통합하여 Neo4j 기반 의료 지식 그래프를 구축하였다. 앞 절의 전처리가 의료 개념 검색을 위한 Description 데이터를 구성하는 과정이라면, 본 절에서는 각 온톨로지의 Concept과 Relationship을 그래프의 Node와 Edge 형태로 변환하고 서로 다른 온톨로지 사이의 연결 관계를 추가하여 Neo4j에 적재하는 과정을 설명한다.

전체 구축 과정은 온톨로지별 Node 및 내부 Relationship 전처리 → 온톨로지 간 관계 매핑 → Neo4j 적재의 순서로 수행하였다.

(1) 온톨로지별 Node 및 내부 Relationship 전처리

SNOMED CT, RxNorm, LOINC는 원본 데이터의 구조와 명명 방식이 서로 다르므로, Neo4j에서 공통적으로 관리할 수 있도록 각 의료 개념을 concept_id, name, ontology,

semantic_type을 중심으로 하는 Node 구조로 변환하고, 각 온톨로지에서 제공하는 개념 간 관계를 Relationship 데이터로 구성하였다.

SNOMED CT에서는 활성 상태의 Concept을 대상으로 Node를 구성하였다. Concept의 명칭은 Description 데이터의 Fully Specified Name(FSN)을 우선적으로 사용하고, FSN이 존재하지 않는 경우 Synonym을 사용하였다. 또한 명칭에 포함된 semantic tag를 이용하여 Disorder, Finding, Procedure, BodyStructure, Organism 등의 semantic type을 부여하였다. Concept 간 관계는 Relationship 데이터의 typeId를 실제 관계명으로 변환하여 구성하고, 동일한 임상 의미를 갖는 관계 그룹을 확인할 수 있도록 relationshipGroup 정보도 유지하였다.

RxNorm에서는 RXNCONSO 데이터를 기반으로 RXCUI별 대표 Concept을 구성하였다. 검색 및 그래프 활용에 필요한 용어를 중심으로 Node를 생성하고 TTY 정보를 이용하여 Drug, DoseForm, MedicalSupply 등의 semantic type을 구분하였다. Concept 간 관계는 RXNREL에서 Concept 간 관계를 추출하고, 역방향 관계가 중복으로 제공되는 경우에는 정방향 관계를 중심으로 정리하였다. 이후 양쪽 Concept이 실제 구축된 RxNorm Node에 존재하는 경우에만 최종 Relationship에 포함하였다.

LOINC에서는 검사 항목과 검사의 구성 정보를 표현하는 Part를 구분하여 Node를 구축하였다. Deprecated 상태의 검사는 제외하고 LONG_COMMON_NAME을 대표 명칭으로 사용하였으며, 검사 항목은 LabTest, ClinicalObservation, ClaimsDocument, Survey 등의 semantic type으로 구분하였다. LOINC의 관계는 LOINC 확장 데이터에 포함된 SNOMED CT 연결 관계, 검사와 6축 구성요소(COMPONENT, PROPERTY, TIME, SYSTEM, SCALE, METHOD) 사이의 관계, 그리고 패널과 구성 검사 사이의 HAS_MEMBER 관계를 통합하여 구성하였다.

(2) 온톨로지 간 관계 매핑

각 온톨로지 내부의 개념과 관계를 구축한 뒤, 질병·약물·검사 정보를 하나의 그래프에서 함께 탐색할 수 있도록 온톨로지 사이의 연결 관계를 추가하였다.

먼저 질환과 약물 사이의 연결을 위해 본 연구의 주요 대상 질환 5개(T2DM, HTN, CKD, HF, COPD)와 해당 질환의 하위 SNOMED CT Concept을 대상으로 UMLS CUI를 이용한 매핑을 수행하였다. 이후 UMLS의 may_treat 및 may_be_treated_by 관계를 활용하여 SNOMED CT 질환 Concept과 RxNorm 약물 Concept 사이에 HAS_DRUG 관계를 생성하

였다.

또한 생성된 약물 관계와 LOINC의 Part 매핑 정보를 이용하여 RxNorm 약물과 LOINC 검사 사이의 HAS_TEST 관계를 추가하였다. 이 과정에서는 RxNorm 약물과 LOINC Part의 연결 정보를 이용해 관련 검사 항목을 탐색하고, LOINC 공식 데이터에서 활성 상태인 검사만 최종 관계에 포함하였다.

이를 통해 SNOMED CT의 질병 및 임상 개념, RxNorm의 약물 정보, LOINC의 검사 정보를 하나의 지식 그래프 안에서 연결하여 탐색할 수 있도록 구성하였다.

(3) Neo4j 적재

전처리 및 관계 매핑을 통해 생성된 Node와 Relationship 데이터는 Neo4j에 적재하였다. Concept Node의 중복 생성을 방지하기 위해 (ontology, concept_id) 조합에 대해 고유 제약조건을 설정하였으며, 그래프 탐색 시 의료 개념 유형을 활용할 수 있도록 semantic_type에 대한 인덱스를 생성하였다.

대규모 데이터를 안정적으로 적재하기 위해 Node와 Relationship 데이터를 10,000건 단위의 Chunk로 나누어 처리하였으며, 기존 데이터와 중복되는 Concept이 생성되지 않도록 MERGE 방식을 사용하였다. 이를 통해 서로 다른 온톨로지에서도 동일한 Concept ID가 존재하더라도 ontology와 concept_id의 조합을 기준으로 각각의 의료 개념을 구분하여 관리할 수 있도록 하였다.

최종적으로 구축된 Neo4j 지식 그래프는 SNOMED CT의 질병·임상 개념, RxNorm의 약물 개념, LOINC의 검사 개념과 이들 사이의 내부 및 교차 온톨로지 관계로 구성되며, 이후 3.3.2 의도 기반 지식 그래프 탐색의 검색 대상으로 사용된다.

구축된 의료 지식 그래프의 전체 구조는 그림 4와 같다. 세 온톨로지의 내부 관계뿐 아니라 질환-약물 및 약물-검사 사이의 교차 온톨로지 관계를 추가하여, 하나의 질의에서 서로 다른 유형의 의료 정보를 연계하여 탐색할 수 있도록 구성하였다.




그림 4. SNOMED CT, RxNorm, LOINC 기반 의료 지식 그래프 구조

3.2.3. 의료 개념 검색 데이터베이스 및 인덱스 구축

3.2.1에서 전처리한 SNOMED CT, RxNorm, LOINC의 의료 Description을 실제 검색에 활용하기 위해 의미 기반 검색을 위한 Qdrant 벡터 데이터베이스와 키워드 기반 검색을 위한 BM25 인덱스를 각각 구축하였다. 두 검색 기반은 동일한 의료 Description을 대상으로 하며, 이후 Entity Linking 단계에서 Hybrid Search를 통해 함께 활용된다.

(1) Embedding 기반 벡터 데이터베이스 구축

의미 기반 의료 개념 검색을 위한 Embedding 모델로 BAAI/bge-base-en-v1.5를 사용하였다[3][4]. 해당 모델은 입력 텍스트를 768차원의 벡터로 변환하며, 벡터 간 코사인 유사도를 이용하여 의미적으로 가까운 의료 표현을 검색할 수 있다.

대규모 의료 데이터를 구축하기에 앞서 Embedding 모델이 서로 다른 의료 표현의 의미적 유사성을 적절히 나타내는지 확인하였다. Type 2 diabetes mellitus, Type II diabetes, Diabetes mellitus type 2와 같이 표현은 다르지만 동일한 의미를 갖는 의료 용어들의 코사인 유사도를 비교한 결과 약 0.84~0.96의 높은 유사도를 보였다. 반면 Kidney disease, Metformin과 같이 서로 다른 의미를 갖는 표현과는 약 0.52~0.64의 상대적으로 낮은 유사도를 보였다. 이를 통해 동일한 의료 개념이 서로 다른 표현으로 입력되더라도 의미적 유사성을 반영할 수 있음을 확인하였다.

```
texts = [
    "Type 2 diabetes mellitus", [[0.9999999 0.8404945 0.96406627 0.5640194 0.64243096]
    "Type II diabetes", [0.8404945 0.9999999 0.86972606 0.56540084 0.62015593]
    "Diabetes mellitus type 2", [0.96406627 0.86972606 0.9999999 0.57808495 0.63066673]
    "Kidney disease", [0.5640194 0.56540084 0.57808495 1. 0.52428514]
    "Metformin" [0.64243096 0.62015593 0.63066673 0.52428514 0.9999998 ]]
]
```

그림 5. 의료 용어 표현 간 Embedding 코사인 유사도 비교

또한 실제 검색 환경에서도 의미 기반 검색이 정상적으로 이루어지는지 확인하였다. 소규모 데이터를 Qdrant에 적재한 뒤 원본 의료 용어인 Neoplasm of esophagus와 표현이 다른 Esophageal neoplasm을 검색 질의로 입력하였다. 그 결과 Neoplasm of esophagus가 높은 유사도 점수와 함께 최상위 의료 개념으로 검색되었으며, 이를 통해 질의와 데이터의 표현이 완전히 일치하지 않는 경우에도 의미적으로 관련된 Concept을 검색할 수 있음을 확인하였다

```
query = "Esophageal neoplasm"

Score : 0.9687          Score : 0.9543
Concept : 126817006     Concept : 126819009
Term : Neoplasm of esophagus   Term : Neoplasm of thoracic esophagus
```

그림 6. Esophageal neoplasm 질의에 대한 Embedding Search 결과

이러한 검증을 바탕으로 3.2.1에서 전처리한 의료 Description을 BGE 모델로 임베딩하여 Qdrant에 저장하였다. 의료 개념 검색용 Collection은 concept_descriptions로 구성하였으며, 768차원 벡터에 대해 Cosine Distance를 이용하여 유사도를 계산하도록 설정하였다. 각 Description에는 벡터와 함께 conceptId, term, descriptionType, ontology 정보를 저장하여 검색된 결과가 어떤 표준 의료 개념에 해당하는지 확인할 수 있도록 하였다.

전체 데이터는 약 159만 건으로 규모가 크기 때문에, 대량 임베딩 과정에서 처리 속도와 GPU 메모리 사용량을 함께 고려할 필요가 있었다. 이에 실제 데이터 적재 전에 Embedding Batch Size를 32, 64, 128, 256으로 변경하면서 처리 성능을 비교하였다. 실험 결과 Batch Size 128에서 10,000건 기준 약 3.7초의 처리 시간과 약 671 MB의 GPU 메모리 사용량을 보여, 처리 속도와 메모리 사용량을 고려한 최종 Batch Size로 채택하였다

batch_size	time_sec	peak_memory_MB
32	5.642423	487.620117
64	4.041100	548.385742
128	3.738894	671.024414
256	3.760736	910.479492

그림 7. Embedding Batch Size별 처리 속도 및 GPU 메모리 사용량 비교

선정한 Batch Size 128을 이용하여 전체 데이터를 순차적으로 임베딩하고 Qdrant에 적재하였으며, 최종적으로 SNOMED CT 1,249,608건, RxNorm 129,472건, LOINC 211,858건 등 총 1,590,938개의 의료 Description 벡터를 concept_descriptions Collection에 구축하였다.

(2) BM25 기반 키워드 검색 인덱스 구축

Embedding Search가 의미적으로 유사한 표현을 검색하는 역할을 하는 것과 함께, 질환명·약물명·검사명 및 약어와 같이 정확한 용어 일치가 중요한 경우를 보완하기 위해 BM25 기반 Keyword Search를 구축하였다.

SNOMED CT, RxNorm, LOINC의 전처리 결과를 하나의 검색 데이터로 통합하고, 각 의료 용어를 소문자로 변환한 뒤 하이픈을 공백으로 처리하여 토큰화하였다. 이후 BM25Okapi를 이용하여 약 159만 건의 의료 Description에 대한 BM25 인덱스를 생성하였다.

이렇게 구축한 Qdrant 기반 Embedding Search와 BM25 기반 Keyword Search는 동일한 의료 개념 데이터에 대해 각각 의미적 유사도와 키워드 일치도를 계산하며, 이후 Hybrid Search 단계에서 두 결과를 결합하여 최종 의료 개념 후보를 선택하도록 구성하였다.

3.2.4. 임상 진료지침 검색 데이터 구축

의료 지식 그래프는 질병, 약물, 검사 등 의료 개념 간의 구조적인 관계를 제공하지만, 실제 진료에서 활용되는 치료 권고, 진단 기준, 목표 수치 및 관리 방법과 같은 정보를 모두 표현하기에는 한계가 있다. 이에 본 연구에서는 임상 진료지침을 별도의 검색 데이터로 구축하여, 사용자 질문과 관련된 임상 권고를 검색하고 답변 생성에 활용할 수 있도록 하였다.

이를 위해 주요 대상 질환에 대한 임상 진료지침 PDF를 수집한 뒤, PDF Parsing → 문서 정제 → Chunking → Embedding → Qdrant 저장 과정을 통해 검색 가능한 형태로 구축하였다.

(1) 임상 진료지침 수집 및 전처리

본 연구에서는 주요 대상 질환과 관련하여 NICE(National Institute for Health and Care Excellence)의 T2DM, HTN, COPD, CKD, HF 진료지침 5종[5]-[9]과 WHO(World Health

Organization)의 T2DM, HTN 진료지침 2종[10][11]을 수집하여, 총 7개의 임상 진료지침 PDF를 검색 데이터 구축 대상으로 사용하였다.

표 5. 임상 진료지침 검색 데이터 구성

발행 기관	대상 질환	문서 수
NICE	Type 2 Diabetes Mellitus, Hypertension, Chronic Obstructive Pulmonary Disease, Chronic Kidney Disease, Heart Failure	5
WHO	Type 2 Diabetes, Hypertension	2
합계		7

원본 PDF를 검색 및 Embedding에 적합한 텍스트 형태로 변환하기 위해 문서 구조 분석 라이브러리인 Docling을 이용하여 Markdown 형식으로 변환하였다. 임상 진료지침에는 일반 문단뿐 아니라 진단 기준이나 위험도 분류와 같은 표, 여러 단계로 구성된 문서 구조가 포함되어 있으므로, 단순 텍스트 추출보다는 제목 계층과 표 등의 문서 구조를 가능한 한 유지할 수 있는 방식이 필요하였다. 특히 Markdown의 제목 구조는 이후 Chunking 과정에서 각 내용이 어떤 Section에 속하는지를 유지하는 데 활용하였다.

변환된 Markdown에는 표지, 목차, 참고문헌 등 실제 임상 지식 검색에 직접적으로 필요하지 않은 내용도 포함되어 있으므로 이를 제거하였다. 또한 검색 및 Embedding에 적합하지 않은 일부 표나 순서도 형태의 정보는 문맥을 유지할 수 있도록 자연어 형태로 정리하였다. 이를 통해 실제 진단, 치료, 검사 및 환자 관리와 관련된 내용이 검색에 활용될 수 있도록 문서를 정제하였다.

(2) Guideline Chunking 및 Metadata 구성

정제된 Markdown 문서를 벡터 검색에 활용하기 위해 문서를 의미 단위의 Chunk로 분할하였다. 먼저 Markdown의 제목 구조(#, ##, ###, ####)를 기준으로 Section 단위의 1차 분할을 적용하였다. 제목 구조를 기준으로 분할하면 서로 다른 주제의 내용이 하나의 Chunk에 혼합되는 것을 줄이고, 검색된 내용이 문서 내 어떤 Section에 해당하는지도 함께 유지할 수 있다.

그러나 제목 구조만을 이용한 분할을 WHO Hypertension 진료지침에 적용한 결과, 총

40개의 Chunk가 생성되었으나 길이가 최소 151자, 최대 5,850자, 평균 1,789.6자로 큰 차이를 보였다. 특히 하나의 Section 아래에 긴 내용이 포함된 경우 하나의 Chunk가 지나치게 커져, 하나의 Embedding 벡터에 서로 다른 세부 내용이 함께 포함될 가능성이 있었다.

이러한 문제를 보완하기 위해 제목 구조를 이용한 1차 분할 후, 일정 크기를 초과하는 Chunk를 다시 분할하는 2단계 Chunking 방식을 적용하였다. 2차 분할에서는 최대 Chunk 크기를 2,000자, Chunk 간 중첩을 200자로 설정하고, 가능한 한 문단과 문장 경계를 우선하여 분할하도록 구성하였다. Chunk 간 일부 내용을 중첩함으로써 분할 지점에서 문맥이 완전히 단절되는 것을 줄였다. 또한 각 Chunk에 상위 제목 정보를 함께 유지하여, 개별 Chunk만 검색되더라도 해당 내용이 어떤 Section에서 나온 것인지 확인할 수 있도록 하였다.

표 6. 임상 진료지침 Chunking 설정

단계	처리 방식	설정
1차 분할	Markdown 제목 구조 기반	# ~ ##### Section 기준
2차 분할	긴 Chunk 재분할	최대 2,000자
문맥 유지	Chunk 간 Overlap	200자
분할 기준	문단·문장 경계 우선	문단 → 문장 → 단어 순
Section 유지	상위 제목 정보 포함	h1~h4 Metadata

이러한 2단계 Chunking 방식을 7개의 모든 진료지침에 공통으로 적용하였다. 각 Chunk에는 검색 결과의 출처와 문서 내 위치를 확인할 수 있도록 organization, disease, h1~h4, chunk_id 정보를 Metadata로 부여하였다. organization은 NICE 또는 WHO와 같은 발행 기관을, disease는 대상 질환을 나타내며, h1~h4는 해당 내용의 문서 내 제목 계층, chunk_id는 문서 내 Chunk의 순서를 나타낸다. 이러한 Metadata는 이후 검색 결과를 LLM의 근거로 구성하고 웹서비스에서 사용자에게 출처를 표시하는 데 활용된다.

(3) Embedding 및 Qdrant 구축

Chunking을 통해 생성된 임상 진료지침의 각 Chunk는 의료 개념 검색에서 사용한 것과 동일한 BAAI/bge-base-en-v1.5 모델을 이용하여 벡터로 변환하였다. 의료 개념

Description과 임상 진료지침은 검색 대상과 목적이 다르므로, Qdrant에는 의료 개념 검색용 concept_descriptions와 별도로 임상 진료지침 검색을 위한 guidelines Collection을 구축하였다.

각 Point에는 Embedding 벡터와 함께 Chunk의 원문 Text 및 organization, disease, h1~h4, chunk_id Metadata를 저장하였다. 의료 개념 검색은 검색된 Concept ID를 이용하여 이후 지식 그래프를 탐색하는 반면, Guideline Retrieval은 검색된 Chunk의 본문 자체를 LLM의 근거로 활용해야 하므로 원문 Text를 Payload에 함께 저장하였다. 이를 통해 검색 결과만으로 해당 권고 내용과 발행 기관, 대상 질환 및 문서 내 Section을 확인할 수 있도록 구성하였다.

이렇게 구축한 guidelines Collection은 이후 사용자 질문을 Embedding한 벡터와 각 Guideline Chunk 간의 유사도를 비교하여 관련성이 높은 임상 진료지침을 검색하는 데 사용된다.

3.3. 핵심 기능 구현

3.3.1. 의료 표현 추출 및 Entity Linking

사용자의 자연어 질문을 지식 그래프의 표준 의료 개념과 연결하기 위해 의료 표현 추출(Mention Detection)과 Hybrid Search 기반 Entity Linking을 구현하였다. 처리 과정은 Mention Detection → Keyword/Embedding Search → Hybrid Search → Concept Set 생성 순으로 진행된다.

(1) 의료 표현 추출(Mention Detection)

Mention Detection은 사용자 질문에서 질병, 약물, 검사, 신체 부위, 시술 등 의료 개념과 관련된 표현을 추출하여 이후 의료 개념 검색의 입력으로 사용하는 단계이다.

본 연구에서는 일반적인 의료 개체명 인식에서 요구되는 Entity Type의 세부 분류보다는, 검색에 필요한 의료 표현을 누락하지 않고 추출하는 것과 여러 단어로 구성된 의료 표현을 하나의 온전한 span으로 추출하는 것을 중요하게 보았다. 추출된 Mention은 이후 Qdrant 기반 Embedding Search와 BM25 기반 Keyword Search의 입력으로 직접 사용되므로, 의료 표현이 중간에 잘리거나 누락될 경우 이후 Entity Linking의 검색 품질에도 영향을 줄 수 있기 때문이다. 이에 Span 품질과 Recall을 주요 모델 선정 기준으로 설정하였다.

이러한 기준으로 Transformer 기반 Biomedical NER 모델인 d4data/biomedical-ner-all[12]과 SciSpacy의 en_core_sci_scibert[13]를 비교하였다. d4data/biomedical-ner-all에서는 hypertension이 hyper, ##tension으로, lisinopril이 li, ##sin, ##op로 분리되는 등 의료 표현이 subword 단위로 추출되는 사례가 나타났으며, 일부 질문에서는 필요한 의료 개념이 누락되기도 하였다. 이러한 결과는 추출된 표현을 그대로 검색어로 사용하기에는 적합하지 않은 것으로 판단하였다

표 7. Mention Detection 후보 모델 비교 예시

질문	기대 Mention	실제 추출 결과
A patient with hypertension is taking lisinopril.	hypertension, lisinopril	hyper, ##tension, li, ##sin, ##op
What are the complications of COPD?	COPD	cop
Which laboratory tests such as BNP are recommended for heart failure?	BNP, Heart failure	laboratory tests, bnp

반면 en_core_sci_scibert는 Type 2 diabetes, chronic kidney disease, kidney function, bronchodilator therapy와 같이 여러 단어로 구성된 의료 표현을 하나의 span으로 안정적으로 추출하였다. 따라서 본 연구의 Mention Detection 목적에 보다 적합하다고 판단하여 SciSpacy의 en_core_sci_scibert를 최종 모델로 채택하였다.

표 8. SciSpacy를 이용한 의료 표현 추출 예시

질문	추출된 Mentions
A patient with Type 2 diabetes is taking metformin.	patient, Type 2 diabetes, metformin
How is chronic kidney disease diagnosed?	chronic kidney disease, diagnosed
Patients with hypertension receiving lisinopril should have their kidney function monitored.	Patients, hypertension, lisinopril, kidney function, monitored
Patients with COPD should undergo spirometry and receive bronchodilator therapy.	Patients, COPD, spirometry, bronchodilator therapy

최종 시스템에서는 사용자 질문을 SciSpacy 모델에 입력하고 doc.ents를 이용하여 인식된 의료 표현을 추출하였다. 동일한 표현이 반복되는 경우 중복을 제거한 뒤, 추출된 Mention을 이후 의료 개념 검색의 입력으로 사용하였다.

예를 들어 다음과 같은 질문이 입력된 경우,

For a patient with COPD experiencing an acute exacerbation, what COPD-related complications should be considered, which medications can be used for treatment, and how should oxygen status be monitored?

질문에서 patient, COPD, acute exacerbation, COPD-related complications, medications, treatment, oxygen status, monitored 등의 표현이 추출되며, 해당 결과를 다음 단계의 Keyword Search 및 Embedding Search에 전달한다.

No.		Mention
0	1	patient
1	2	COPD
2	3	acute exacerbation
3	4	COPD-related complications
4	5	medications
5	6	treatment
6	7	oxygen status
7	8	monitored

그림 8. 사용자 질문의 의료 표현 추출 결과

SciSpacy는 의료 표현의 Recall을 높이는 과정에서 patient, diagnosed, monitored와 같이 핵심 의료 개념이 아닌 표현을 일부 함께 추출할 수 있다. 본 연구에서는 Mention Detection 단계에서 과도하게 후보를 제거하기보다 필요한 의료 표현을 놓치지 않는 것을 우선하였다. 이후 의료 Description과의 검색 결과, 지식 그래프 탐색 조건, Graph Context 정제 과정에서 질문과 관련성이 낮은 정보가 단계적으로 제한되도록 구성하였다.

(2) Keyword Search 및 Embedding Search

Mention Detection을 통해 추출된 각 의료 표현에 대해 3.2.3에서 구축한 BM25 기반 Keyword Search와 Qdrant 기반 Embedding Search를 각각 수행하였다. 두 검색 방식은 동일한 SNOMED CT, RxNorm, LOINC의 의료 Description을 대상으로 하지만, 서로 다른

기준으로 관련 Concept을 탐색한다.

Keyword Search는 BM25를 이용하여 입력 표현과 의료 용어 사이의 문자적 일치 정도를 계산한다. 따라서 질환명, 약물명, 검사명이나 약어처럼 정확한 용어가 질문에 포함된 경우 관련 Concept을 효과적으로 검색할 수 있다. 반면 Embedding Search는 입력된 의료 표현을 BGE Embedding 모델로 벡터화한 뒤, Qdrant의 concept_descriptions Collection에서 코사인 유사도가 높은 의료 Description을 검색한다. 이를 통해 질문의 표현이 표준 의료 용어와 완전히 일치하지 않는 경우에도 의미적으로 관련된 Concept을 검색할 수 있도록 하였다.

표 9. Keyword Search와 Embedding Search 비교

검색 방식	구현 방법	주요 특징
Keyword Search	BM25	입력 표현과 의료 용어 사이의 문자적 일치 정도를 반영
Embedding Search	SentenceTransformer + Qdrant	입력 표현과 의미적으로 유사한 의료 개념 검색

구현한 검색 기능이 의도대로 동작하는지 확인하기 위해 질환, 약물, 검사명과 자연어 표현을 이용하여 검색 결과를 검증하였다. hypertension, metformin, HbA1c처럼 검색 데이터에 직접적으로 대응되는 표현을 입력한 경우 관련 Concept이 높은 점수로 검색되었으며, high blood sugar처럼 표준 의료 용어와 표현이 다른 질의에서도 Embedding Search는 High glucose level in blood, Increased glucose level 등 의미적으로 유사한 Concept을 상위 결과로 반환하였다. 반면 Keyword Search는 동일한 단어가 포함된 항목을 중심으로 검색하는 특성을 보였다. 이를 통해 두 방식이 서로 다른 검색 특성을 가지며, 이후 Hybrid Search에서 상호 보완적으로 활용할 수 있음을 확인하였다.

```
query = "high blood sugar"
```

Qdrant	BM25
[{'conceptId': '444780001', 'term': 'High glucose level in blood', 'descriptionType': 'Synonym', 'ontology': 'SNOMED', 'score': 0.9000796}, { 'conceptId': '68256003', 'term': 'Increased glucose level', 'descriptionType': 'Synonym', 'ontology': 'SNOMED', 'score': 0.85728574}, { 'conceptId': '444751005', 'term': 'High haemoglobin A1c level', 'descriptionType': 'Synonym', 'ontology': 'SNOMED', 'score': 0.8291811}]	[{'conceptId': '789495009', 'term': 'High blood sugar correction dose', 'descriptionType': 'Synonym', 'ontology': 'SNOMED', 'score': 18.768785426070508}, { 'conceptId': '228072002', 'term': 'High sugar food', 'descriptionType': 'Synonym', 'ontology': 'SNOMED', 'score': 17.58807465536838}, { 'conceptId': '412744006', 'term': 'High sugar diet', 'descriptionType': 'FSN', 'ontology': 'SNOMED', 'score': 17.58807465536838}]

그림 9. high blood sugar 질의에 대한 Embedding Search와 Keyword Search 결과 비교

각 의료 Concept에는 FSN, Synonym 등 여러 Description이 존재할 수 있으므로, 검색 결과에서 동일한 Concept이 서로 다른 표현으로 반복적으로 나타나는 경우가 발생하였다. 그러나 Entity Linking의 목적은 가장 적절한 표준 의료 Concept을 찾는 것이므로, 두 검색 방식 모두 conceptId를 기준으로 중복을 제거하고 동일 Concept에 대해서는 가장 높은 점수를 가진 Description만 유지하였다.

이때 여러 Description의 점수를 합산하지 않은 이유는 Synonym 수가 많은 Concept에 불필요한 가중치가 부여되는 것을 방지하기 위해서이다. 이를 통해 하나의 Concept이 검색 순위를 반복적으로 차지하지 않도록 하고, 서로 다른 의료 개념을 후보로 확보할 수 있도록 하였다.

중복 제거 후에도 필요한 수의 고유 Concept을 확보하기 위해 각 검색 방식에서 목표로 하는 고유 Concept 반환 수보다 많은 Description을 우선 검색하였으며, 내부 검색 수는 목표 반환 수의 2배로 설정하였다. 이를 통해 중복 제거 후에도 필요한 수의 고유 Concept을 안정적으로 확보할 수 있도록 하였다.

# top_k=5 x N=2 qdrant_check_n(limit=10)		# top_k=5 x N=2 bm25_check_n(limit=10)	
type 2 diabetes	Descriptions=10 Concepts= 5	type 2 diabetes	Descriptions=10 Concepts= 6
hypertension	Descriptions=10 Concepts= 9	hypertension	Descriptions=10 Concepts= 7
chronic kidney disease	Descriptions=10 Concepts= 5	chronic kidney disease	Descriptions=10 Concepts= 7
heart failure	Descriptions=10 Concepts= 7	heart failure	Descriptions=10 Concepts= 9
COPD	Descriptions=10 Concepts= 7	COPD	Descriptions=10 Concepts=10
metformin	Descriptions=10 Concepts= 6	metformin	Descriptions=10 Concepts= 8
insulin	Descriptions=10 Concepts= 6	insulin	Descriptions=10 Concepts= 9
HbA1c	Descriptions=10 Concepts= 5	HbA1c	Descriptions=10 Concepts= 8
eGFR	Descriptions=10 Concepts= 7	eGFR	Descriptions=10 Concepts=10
glucose	Descriptions=10 Concepts= 8	glucose	Descriptions=10 Concepts=10

그림 10. 중복 제거 후 고유 Concept 확보를 위한 내부 검색 범위 검증

(3) Hybrid Search

Keyword Search와 Embedding Search는 각각 키워드 일치도와 의미적 유사도라는 서로 다른 기준으로 의료 개념 후보를 검색한다. 따라서 두 검색 결과를 하나의 순위로 통합하기 위해 Hybrid Search를 적용하였다.

각 의료 표현에 대해 Keyword Search와 Embedding Search에서 각각 후보 Concept을 검색한 뒤, conceptId와 ontology를 기준으로 두 결과를 통합하였다. 이때 한쪽 검색 방식에서만 검색된 Concept도 후보에서 제외하지 않고 유지하였다.

두 검색 방식의 점수 범위는 서로 다르기 때문에 그대로 결합할 경우 특정 검색 방식의 점수 크기에 의해 결과가 편향될 수 있다. 이에 BM25 Score와 Embedding Score에 각각 Min-Max 정규화를 적용하여 0~1 범위로 변환한 후 가중합하였다. Hybrid Score는 다음과 같이 계산하였다

$$Hybrid\ Score = 0.8 \times Embedding\ Score_{norm} + 0.2 \times BM25\ Score_{norm}$$

본 연구에서는 Embedding Search에 0.8, Keyword Search에 0.2의 가중치를 적용하였다. 사용자 질문에는 표준 의료 용어와 완전히 동일한 표현뿐 아니라 high blood sugar, medicine for diabetes와 같은 자연어 표현이나 동의어가 포함될 수 있으므로, 의미적 유사성을 반영하는 Embedding Search를 주 검색 방식으로 설정하였다. 반면 BM25는 정확한 질환명, 약물명 및 약어가 입력된 경우 검색 순위를 보완하는 역할로 활용하였다.

query = "type 2 diabetes"

Qdrant	BM25
[{'conceptId': '44054006', 'term': 'Type 2 diabetes mellitus', 'descriptionType': 'Synonym', 'ontology': 'SNOMED', 'score': 0.9281059}, { 'conceptId': '81531005', 'term': 'Type 2 diabetes mellitus in obese', 'descriptionType': 'Synonym', 'ontology': 'SNOMED', 'score': 0.8637958}, { 'conceptId': '190384004', 'term': 'Type II diabetes mellitus', 'descriptionType': 'FSN', 'ontology': 'SNOMED', 'score': 0.85694194}]	[{'conceptId': '44054006', 'term': 'Diabetes mellitus type 2', 'descriptionType': 'Synonym', 'ontology': 'SNOMED', 'score': 17.513485828376574}, { 'conceptId': '445353002', 'term': 'Brittle type 2 diabetes mellitus', 'descriptionType': 'FSN', 'ontology': 'SNOMED', 'score': 15.939173503905668}, { 'conceptId': '424989000', 'term': 'Diabetes type 2 with gastroparesis', 'descriptionType': 'Synonym', 'ontology': 'SNOMED', 'score': 15.939173503905668}]

그림 11. type 2 diabetes 질의에 대한 Embedding Search와 Keyword Search 결과 비교

type 2 diabetes처럼 검색 데이터에 직접적으로 대응되는 표현이 입력된 경우에는

Embedding Search와 Keyword Search 모두 관련된 제2형 당뇨병 Concept을 상위에 검색하였다. 반면 앞서 그림 9의 high blood sugar 사례에서는 Embedding Search가 High glucose level in blood와 같은 의미적으로 관련된 Concept을 검색한 반면, Keyword Search는 High sugar food, High sugar diet와 같이 동일 키워드가 포함된 Concept을 중심으로 검색하였다. 이러한 차이를 고려하여 의미 기반 검색을 중심으로 두 검색 결과를 결합하였다.

Hybrid Search에서는 각 검색 방식으로부터 20개의 후보 Concept을 우선 확보한 뒤 점수를 결합하고, 최종적으로 각 Mention별 상위 3개의 Concept을 선택하였다. 두 검색 방식의 결과에는 서로 다른 Concept이 포함될 수 있으므로, 결합 전에 충분한 후보군을 확보하기 위해 20개를 검색 대상으로 사용하였다. 반면 최종 후보가 지나치게 많으면 이후 Neo4j 그래프 탐색의 시작점이 증가하여 검색 범위와 노이즈가 함께 커질 수 있으므로, 각 Mention별 최종 후보는 상위 3개로 제한하였다.

이러한 과정을 실제 COPD 예시 질문에 적용한 Hybrid Search 결과 일부는 그림 12와 같다.

	mention	conceptid	term	ontology	qdrant_score_norm	bm25_score_norm	hybrid_score
0	COPD	13645005	COPD - Chronic obstructive pulmonary disease	SNOMED	1.000000	1.000000	1.000000
1	COPD	741056003	COPD (chronic obstructive pulmonary disease) e...	SNOMED	0.933811	0.917523	0.930554
2	COPD	1388297006	Pre-COPD (chronic obstructive pulmonary disease)	SNOMED	0.914396	0.917523	0.915022
3	medications	19789-7	Medications	LOINC	1.000000	1.000000	1.000000
4	medications	30964-1	Other medications	LOINC	0.865519	0.876916	0.867798
5	medications	2533004	Medication	SNOMED	0.941397	0.000000	0.753117
6	oxygen status	7806	oxygen	RXNORM	0.969345	1.000000	0.975476
7	oxygen status	24099007	Oxygen	SNOMED	0.969345	1.000000	0.975476
8	oxygen status	736015003	Observable related to oxygenation status	SNOMED	1.000000	0.000000	0.800000

그림 12. Hybrid Search를 통한 의료 개념 검색 결과 일부

각 Mention에 대해 두 검색 방식의 점수를 결합하여 Hybrid Score를 계산하고, 점수가 높은 Concept을 최종 후보로 선택하였다.

(4) Concept Set 생성

각 의료 표현에서 선택된 Hybrid Search 결과를 통합하여 최종 Concept Set을 구성하였다. 하나의 질문에서는 여러 Mention이 추출되고 각 Mention마다 최대 3개의 의료 개념 후보가 생성되므로, 전체 검색 결과를 하나로 결합한 뒤 동일한 의료 Concept이 반복되

는 경우 중복을 제거하였다.

이때 서로 다른 온톨로지에서 동일한 의료 표현이 각각 별도의 Concept으로 존재하는 경우에는 이를 하나로 제거하지 않고 유지하였다. SNOMED CT, RxNorm, LOINC는 동일한 의료 표현을 서로 다른 관점에서 표현할 수 있으며, 이후 지식 그래프 탐색에서도 온톨로지별 관계 구조가 다르기 때문이다. 예를 들어 metformin은 SNOMED CT의 임상 개념과 RxNorm의 약물 Concept으로 각각 연결될 수 있으며, 두 Concept을 모두 유지하여 각 온톨로지에서 관련 관계를 탐색할 수 있도록 하였다.

최종 Concept Set에는 질문에서 추출된 원본 의료 표현인 mention, 표준 의료 개념의 고유 식별자인 conceptId, 연결된 의료 개념 명칭인 term, 해당 개념의 출처인 ontology 정보를 포함하였다.

표 10. Concept Set 구성 정보

필드	내용
mention	사용자 질문에서 추출된 원본 의료 표현
conceptId	표준 의료 개념의 고유 ID
term	연결된 의료 개념 명칭
ontology	SNOMED CT, RxNorm, LOINC 등 소속 온톨로지

실제 COPD 예시 질문에서 Entity Linking을 통해 생성된 Concept Set은 그림 13과 같다.

	mention	conceptId	term	ontology
0	patient	266938001	Hospital patient	SNOMED
1	patient	160740007	Hospital patient	SNOMED
2	patient	788167006	Patient treated with medication	SNOMED
3	COPD	13645005	COPD - Chronic obstructive pulmonary disease	SNOMED
4	COPD	741056003	COPD (chronic obstructive pulmonary disease) e...	SNOMED
5	COPD	1388297006	Pre-COPD (chronic obstructive pulmonary disease)	SNOMED
6	acute exacerbation	708038006	Acute exacerbation of asthma	SNOMED
7	acute exacerbation	708093000	Acute exacerbation of extrinsic asthma	SNOMED
8	acute exacerbation	445378003	Acute exacerbation of bronchiectasis	SNOMED
9	COPD-related complications	157781004	Respiratory complications of care	SNOMED
10	COPD-related complications	213222008	Respiratory complications of care	SNOMED
11	COPD-related complications	62907002	Respiratory complication	SNOMED
12	medications	19789-7	Medications	LOINC
13	medications	30964-1	Other medications	LOINC
14	medications	2533004	Medication	SNOMED
15	treatment	110363002	Treatment pain	SNOMED
16	treatment	371133007	Treatment modification	SNOMED
17	treatment	7922000	General treatment	SNOMED
18	oxygen status	7806	oxygen	RXNORM
19	oxygen status	24099007	Oxygen	SNOMED
20	oxygen status	736015003	Observable related to oxygenation status	SNOMED
21	monitored	270445003	Diabetes monitored	SNOMED
22	monitored	185762001	Diabetes monitored	SNOMED
23	monitored	185738006	Asthma monitored	SNOMED

그림 13. Entity Linking을 통해 생성된 Concept Set 예시

생성된 Concept Set은 이후 Neo4j 지식 그래프 탐색의 시작 개념으로 사용된다.

3.3.2. 의도 기반 지식 그래프 탐색

3.3.1에서 생성된 Concept Set을 시작점으로 Neo4j 지식 그래프를 탐색하였다. 모든 관계를 동일하게 탐색하지 않고, 사용자 질문의 의도와 온톨로지의 관계 특성에 따라 탐색 범위와 방향을 조정하였다. 전체 과정은 질문 의도 분류 → 탐색 관계 및 범위 결정 → Hub Node 확장 제한 → BFS 탐색 → Path 생성의 순서로 수행하였다.

(1) 질문 의도 분류

사용자 질문의 키워드와 Concept Set의 온톨로지 정보를 이용하여 질문 의도를 다음 네

유형 중 하나 이상으로 분류하였다.

표 11. 지식 그래프 탐색을 위한 질문 의도 분류

의도	주요 질문 유형	대표 표현
DRUG	약물, 치료, 처방 관련 질문	drug, medication, treatment, dose
TEST	검사, 모니터링, 측정 관련 질문	test, lab, monitor, screening
PATHO	원인, 증상, 합병증, 발생 부위 관련 질문	cause, complication, symptom
COMPREHENSIVE	특정 의도에 분류되지 않는 일반 질문	별도 일치 키워드가 없는 경우

의도 분류는 질문에 포함된 키워드를 기준으로 수행하며, Concept Set의 온톨로지 정보도 함께 활용한다. Concept Set에 RxNorm 개념이 포함된 경우 DRUG, LOINC 개념이 포함된 경우 TEST 신호를 추가로 반영한다. 특정 의도가 탐지되지 않는 경우에는 COMPREHENSIVE로 분류한다.

예를 들어 다음 질문을 입력하였다:

For a patient with COPD experiencing an acute exacerbation, what COPD-related complications should be considered, which medications can be used for treatment, and how should oxygen status be monitored?

해당 질문에서는 medications, treatment 등의 표현으로 인해 DRUG 의도가, monitored 표현으로 인해 TEST 의도가, complications 표현으로 인해 PATHO 의도가 탐지되었다. 또한 Concept Set에 포함된 RxNorm 및 LOINC 계열 의료 개념은 각각 DRUG와 TEST 의도 판단에 추가적으로 반영된다. 따라서 본 질문에서는 DRUG, TEST, PATHO의 세 의도가 함께 활성화되었다.

```
Intent Classification Result
=====
• DRUG
• TEST
• PATHO
```

그림 14. 사용자 질문에 대한 의도 분류 결과

(2) 온톨로지 및 관계별 탐색 범위 설정

분류된 질문 의도와 각 온톨로지의 관계 특성을 기반으로 탐색에 사용할 관계를 선정하고, 관계별 최대 Hop 수와 탐색 방향을 설정하였다. 탐색 관계는 본 연구의 주요 대상 질환 5개를 중심으로 각 관계를 따라 연결되는 Node의 규모와 실제 검색 결과의 의학적 활용 가능성을 확인하여 선정하였다.

Hop 수는 전체적으로 최대 3-Hop으로 제한하되, 각 관계에 대해 Hop별 탐색 규모를 비교하여 불필요한 그래프 확장을 억제하면서 질문과 관련된 정보를 확보할 수 있는 범위로 설정하였다. 또한 탐색 방향은 관계가 나타내는 의미와 지식 그래프에 저장된 연결 방향을 고려하여 결정하였다. 계층 관계와 같이 양방향 탐색이 의미를 갖는 경우에는 Both를 적용하고, 질환에서 발생 부위나 치료 약물로 연결되는 관계처럼 특정 방향에서 의미가 성립하는 경우에는 Out 또는 In 방향을 적용하였다.

표 12. 온톨로지별 탐색 관계와 조건

온톨로지	관계	최대 Hop	방향
SNOMED CT	IS_A	2	Both
	FINDING_SITE	2	Out
	DUE_TO	3	Both
	ASSOCIATED_MORPHOLOGY, CAUSATIVE_AGENT, OCCURRENCE, INTERPRETS, HAS_DRUG	3	Out
RxNorm	IS_A, HAS_INGREDIENT, HAS_TRADENAME, CONSISTS_OF, HAS_FORM, HAS_PART	2	Both
	HAS_DOSE_FORM	3	In
	HAS_DRUG, HAS_TEST	3	Both
LOINC	IS_A, HAS_MEMBER	2	both
	COMPONENT	3	Out
	HAS_TEST	3	Both
	SCALE, TIME, PROPERTY, SYSTEM, METHOD	1	Out

전체 그래프 탐색 깊이는 최대 3-Hop으로 제한하되, 관계별 탐색 범위와 방향을 구분

하여 불필요한 그래프 확장을 줄였다. SNOMED CT에서는 질문 의도에 따라 탐색 관계를 추가로 제한하며, RxNorm과 LOINC는 각 온톨로지에 설정된 관계를 기준으로 탐색한다.

(3) Hub Node 확장 제한

의료 지식 그래프에는 일부 Concept에 매우 많은 관계가 집중되어 있어, 이러한 Node를 계속 확장할 경우 탐색 범위가 급격하게 증가하고 질문과 관련성이 낮은 정보가 과도하게 포함될 수 있다. 이에 실제 그래프에서 탐색에 사용되는 관계를 기준으로 Node의 degree(연결 정도) 분포를 확인하였다.

분석 결과 전체 Node의 degree 중앙값(50백분위수)은 3인 반면, 최대 degree는 15,632로 나타나 일부 Node에 관계가 극단적으로 집중되어 있음을 확인하였다. 이를 바탕으로 degree 분포의 상위 0.01%에 해당하는 경계값인 768을 기준으로, degree가 768을 초과하는 Node를 Hub Node로 판정하였다.

Hub Node는 탐색 결과에 포함될 수 있도록 해당 Node까지 도달하는 것은 허용하되, 다음 Hop의 확장 대상으로는 사용하지 않도록 하였다. 이를 통해 질문과 관련된 Concept 자체는 검색 결과에 유지하면서도, 연결 수가 지나치게 많은 Node를 경유하여 탐색 범위가 과도하게 확장되는 것을 방지하였다.

(4) BFS 기반 지식 그래프 탐색

Concept Set의 각 Concept을 독립적인 시작 Node로 설정하고 Breadth-First Search(BFS) 방식으로 Neo4j 지식 그래프를 탐색하였다. 각 시작 Concept마다 질문 의도와 온톨로지에 따라 활성화된 관계, 관계별 탐색 방향 및 최대 Hop 수를 적용하여 탐색 범위를 제한하였다.

각 Hop에서는 현재 탐색 대상인 Frontier Node를 온톨로지별로 묶어 Neo4j에 Cypher Query를 실행하였으며, 이미 방문한 Node는 다시 확장하지 않도록 하였다. 이를 통해 동일한 Concept을 반복적으로 탐색하는 것을 방지하면서 필요한 관계를 단계적으로 확장하였다.

새롭게 탐색된 Node 가운데 앞 절에서 정의한 Hub Node는 해당 Hop의 탐색 결과에는 포함하되, 다음 Hop의 Frontier에는 포함하지 않았다. 따라서 질문과 관련된 고연결 Concept 자체는 검색 결과에 유지하면서도, 해당 Node를 경유하여 탐색 범위가 급격하

게 증가하는 것을 제한하였다.

이러한 탐색은 Concept Set에 포함된 각 시작 Concept에 대해 독립적으로 수행하였으며, 각 시작점에서 탐색된 의료 개념과 관계 정보를 이후 Path 생성 단계에 전달하였다.

	concept_id	ontology	name	path_count
11	62907002	SNOMED_CT	Respiratory complication	3463
10	213222008	SNOMED_CT	Respiratory complications of care	1128
3	13645005	SNOMED_CT	Chronic obstructive pulmonary disease	310
17	7922000	SNOMED_CT	General treatment	281
18	7806	RxNorm	oxygen	189
7	708093000	SNOMED_CT	Acute exacerbation of immunoglobulin E-mediate...	128
19	24099007	SNOMED_CT	Oxygen	72
13	30964-1	LOINC	Other medications	69
8	445378003	SNOMED_CT	Acute exacerbation of bronchiectasis	66
20	736015003	SNOMED_CT	Observable related to oxygenation status	60
0	266938001	SNOMED_CT	Hospital patient	25
21	270445003	SNOMED_CT	Diabetes monitoring check done	23

그림 15. 주요 시작 개념별 Neo4j 지식 그래프 탐색 결과

그림 15는 예시 질문에서 Concept Set의 주요 시작 Concept별로 Neo4j 탐색을 수행한 결과를 나타낸다. path_count는 각 시작 Concept에서 설정된 관계와 탐색 조건을 적용하여 생성된 Path의 수를 의미한다.

(5) Path 생성

BFS 탐색 결과를 이용하여 각 시작 Concept에서 탐색된 의료 Concept까지의 관계를 Path 형태로 구성하였다. Path는 단순히 탐색된 Node의 목록을 저장하는 것이 아니라, 시작 Concept에서 대상 Concept까지 어떤 관계와 방향을 따라 도달했는지를 유지하도록 구성하였다.

각 Path에는 시작 Concept의 정보, 탐색된 대상 Concept, 시작점으로부터의 탐색 깊이 (Hop), 그리고 경로를 구성하는 Node와 Relationship의 순서 및 방향 정보를 포함하였다.

표 13. 지식 그래프 탐색 Path의 구성 정보

구성 요소	내용
Start	탐색을 시작한 Concept의 ID, ontology 및 이름
Target	탐색을 통해 도달한 Concept의 ID, ontology 및 이름
Hop	시작 Node에서 Target까지의 탐색 깊이
Steps	경로를 구성하는 Node, Relationship 및 탐색 방향

생성된 Path는 전체 탐색 결과에 통합하여 저장하였으며, 각 시작 Concept별로 생성된 Path의 수도 함께 관리하였다. 시작 Concept 정보를 Path에 유지함으로써 동일한 의료 개념이 여러 경로에서 검색되더라도 어떤 Concept을 시작점으로 탐색된 결과인지 확인할 수 있도록 하였다.

생성된 Path는 이후 3.3.3 Graph Context 생성 단계의 입력으로 사용되며, 질문 의도와 관계의 중요도에 따라 정제된 후 LLM이 활용할 수 있는 자연어 형태의 Graph Context로 변환된다.

3.3.3. Graph Context 생성

3.3.2에서 Neo4j를 통해 탐색된 Path는 그대로 LLM에 전달하지 않고, 질문 의도와 관계의 중요도를 반영하여 자연어 형태의 Graph Context로 변환하였다. 또한 동일한 근거를 프론트엔드 지식 그래프 시각화에도 사용할 수 있도록 그래프 데이터를 함께 생성하였다.

전체 과정은 그림 16과 같이 정리할 수 있다.




그림 16. Graph Context 생성 전체 흐름

(1) 탐색 Path 전처리 및 Tree 구성

Neo4j에서 반환된 Path에는 여러 탐색 path가 동일한 Prefix를 공유하거나, 동일 관계를 따라 이동한 직후 반대 방향으로 되돌아가는 불필요한 탐색 결과가 포함될 수 있다. 따라서 다음과 같이 Path를 전처리하였다.

- 동일 관계를 직전 간선과 반대 방향으로 되짚는 Path 제거
- 여러 Path에서 공유되는 공통 Prefix를 Tree 구조로 통합
- Tree 구성 과정에서 중복되는 관계 구조 정리
- Concept 이름이 없는 경우 ontology:concept_id 형태의 식별자로 대체

이를 통해 개별 Path를 단순히 나열하는 대신, 공통 탐색 구조를 공유하는 계층적 Tree 형태로 관계 정보를 정리하였다.

(2) 관계 기반 자연어 문장 변환

Tree에 포함된 의료 개념과 관계를 LLM이 해석할 수 있도록, 관계 유형과 탐색 방향에 따라 정의된 자연어 템플릿을 적용하였다. 관계의 의미가 탐색 방향에 따라 달라질 수 있으므로, 각 (relation, direction) 조합에 따라 서로 다른 자연어 템플릿을 적용하였다.

표 14. 주요 그래프 관계의 자연어 변환 예시

관계	자연어 변환 예시
IS_A	A is a type of B
FINDING_SITE	A occurs at B
DUE_TO	A can occur as a result of B
INTERPRETS	A is assessed by evaluating B
HAS_DRUG	B may be used to treat A
HAS_TEST	A is monitored by the test B
COMPONENT	A measures B
SYSTEM	A is measured in the specimen B
PROPERTY	A measures the property B

SNOMED CT, RxNorm, LOINC의 주요 관계에 대해 관계 유형과 탐색 방향별 자연어 템플릿을 정의하였다. 이를 통해 단순 개념 목록이 아니라 의료 개념 간 관계가 유지된 문장 형태의 Graph Context를 생성하였다.

(3) 질문 의도 기반 Graph Context 정제

탐색된 Path의 수가 많을 경우 생성되는 Graph Context가 지나치게 길어질 수 있으므로, 본 연구에서는 Graph Context의 최대 길이를 20,000자로 제한하였다. 먼저 전처리된 Path 전체를 자연어 형태로 변환하고, 최대 길이를 초과하는 경우 질문 의도와 관계 유형을 기준으로 단계적으로 정제하였다.

1차적으로 전체 Path를 Graph Context로 구성한 뒤, 20,000자를 초과하는 경우 질문 의도와 관련성이 낮은 관계로 끝나는 Path를 제거하는 Hard Filtering을 적용하였다. 이후에도 최대 길이를 초과하는 경우에는 관계의 중요도와 남은 문자 예산을 함께 고려하여 우선순위가 높은 관계부터 선택하였다.

표 15. Graph Context 정제 단계

단계	처리 방식
1단계	전처리된 Path 전체를 Graph Context로 우선 변환
2단계	20,000자 초과 시 질문 의도와 관련성이 낮은 관계로 끝나는 Path를 Hard Filtering
3단계	여전히 초과할 경우 관계 우선순위와 문자 예산을 적용하여 중요 관계부터 유지

질문 의도에 따라 관계의 유지 우선순위가 다르게 적용하였다. 예를 들어 DRUG 의도에서는 HAS_DRUG, HAS_TRADENAME 등 약물 관련 관계를 우선하고, TEST 의도에서는 HAS_TEST, INTERPRETS, COMPONENT, SYSTEM, PROPERTY 등 검사 관련 관계를 우선하였다.

이때 우선순위 기반 정제는 특정 관계 유형을 일괄적으로 제거하는 방식이 아니라, Tree에 포함된 개별 Edge마다 질문 의도와 관계 유형에 따른 우선순위를 부여하고, 제한된 문자 예산 안에서 우선순위가 높은 Edge부터 선택하는 방식으로 수행하였다. 이를 통해 Graph Context의 길이를 제한하면서도 사용자 질문과 직접적으로 관련된 관계를 가능한

한 유지하도록 구성하였다.




그림 17. Graph Context 정제 과정

(4) LLM용 Context 및 시각화 데이터 생성

최종적으로 정제된 그래프 관계는 LLM 입력용 Graph Context와 프론트엔드 시각화용 Graph 데이터의 두 가지 형태로 생성하였다.

표 16. Graph Context 생성 결과

반환 정보	활용 목적
context_text	LLM Prompt에 전달되는 자연어 Graph Context
graph	프론트엔드 지식 그래프 시각화를 위한 Node/Edge 데이터

context_text는 앞 단계에서 최종적으로 선택된 관계를 자연어 문장으로 변환하여 구성한다. 시각화용 graph는 context_text 생성 과정에서 실제로 채택된 관계를 기준으로 Node와 Edge를 생성하므로, LLM에 제공되는 그래프 근거와 사용자에게 표시되는 지식 그래프는 동일한 검색 결과를 기반으로 구성된다.

시각화용 Graph 데이터는 Node와 Edge로 구성하였으며, 각 요소의 주요 정보는 표 17과 같다.

표 17. 지식 그래프 시각화 데이터 구성

구분	주요 정보	내용
Node	concept_id	의료 Concept의 식별자
	ontology	Concept이 속한 온톨로지
	name	Concept의 이름
	is_root	질문에서 추출된 시작 Concept 여부
Edge	source	관계의 시작 Node ID
	target	관계의 대상 Node ID
	relation	의료 개념 간 관계 유형
	direction	Neo4j에서의 관계 방향

서로 다른 온톨로지에서도 동일한 Concept ID가 존재할 수 있으므로, Node의 고유 식별자는 `ontology:concept_id` 형식으로 구성하였다. 예를 들어 SNOMED CT의 Concept ID 44054006은 SNOMED_CT:44054006과 같이 표현된다.

프론트엔드에서는 시각적 복잡도를 줄이기 위해 HAS_TRADENAME, HAS_PART, HAS_INGREDIENT 관계가 시작 개념에서 2-Hop 이상 떨어진 경우 화면 표시 대상에서 제외하도록 하였다. 이는 프론트엔드 시각화를 위한 제한으로, LLM에 전달되는 `context_text`에는 영향을 주지 않는다.

```
Chronic obstructive pulmonary disease
Asthma-chronic obstructive pulmonary disease overlap syndrome is a more specific subtype of Chronic obstructive pulmonary disease
Roflumilast may be used to treat Chronic obstructive pulmonary disease
Daliresp is a brand name for roflumilast
Zoryve is a brand name for roflumilast
Acclidinium bromide may be used to treat Chronic obstructive pulmonary disease
Acclidinium may be used to treat Chronic obstructive pulmonary disease
Tudorza is a brand name for acclidinium
Duaklir is a brand name for acclidinium
End stage chronic obstructive pulmonary disease is a more specific subtype of Chronic obstructive pulmonary disease
Chronic obstructive pulmonary disease of unknown cause is a more specific subtype of Chronic obstructive pulmonary disease
Chronic obstructive pulmonary disease is a type of Chronic disease of respiratory system
Acute exacerbation of chronic obstructive pulmonary disease is a more specific subtype of Chronic obstructive pulmonary disease
Chronic obstructive pulmonary disease with acute bronchitis is a more specific subtype of Acute exacerbation of chronic obstructive pulmonary disease
Acute exacerbation of chronic obstructive pulmonary disease with asthma is a more specific subtype of Acute exacerbation of chronic obstructive pulmonary disease
Chronic obstructive pulmonary disease with acute lower respiratory infection is a more specific subtype of Acute exacerbation of chronic obstructive pulmonary disease
Revefenacin may be used to treat Chronic obstructive pulmonary disease
Yupelri is a brand name for revefenacin
Chronic obstructive pulmonary disease is a type of Tracheobronchial disorder
Ensifentrine may be used to treat Chronic obstructive pulmonary disease
Ohtuvayre is a brand name for ensifentrine
Mild chronic obstructive pulmonary disease is a more specific subtype of Chronic obstructive pulmonary disease
Moderate chronic obstructive pulmonary disease is a more specific subtype of Chronic obstructive pulmonary disease
Severe chronic obstructive pulmonary disease is a more specific subtype of Chronic obstructive pulmonary disease
Chronic obliterative bronchiolitis is a more specific subtype of Chronic obstructive pulmonary disease
```

그림 18. Neo4j 탐색 결과로부터 생성된 Graph Context 일부 예시

그림 18은 Neo4j에서 탐색된 의료 개념과 관계가 자연어 형태의 Graph Context로 변환된 일부 결과를 보여준다. 본 예시에서는 COPD 및 급성 악화 관련 개념의 IS_A 관계와

COPD 치료 약물에 대한 HAS_DRUG 관계 등이 검색되었으며, 각 관계는 정의된 관계 유형과 탐색 방향에 따른 자연어 템플릿을 이용하여 문장 형태로 변환되었다. 생성된 context_text는 이후 답변 생성 Prompt에서 지식 그래프 기반 근거로 활용된다.

3.3.4. 임상 진료지침 검색 및 Context 구성

GraphRAG를 통해 의료 개념 간의 구조적 관계를 검색하는 것과 함께, 실제 치료·검사·모니터링 등과 관련된 임상 권고를 답변 근거로 활용하기 위해 Clinical Guideline 검색 기능을 구현하였다. 사용자의 질문을 임베딩한 후 3.2.4에서 구축한 Qdrant의 guidelines Collection에서 의미적으로 관련성이 높은 Guideline Chunk를 검색하고, 상위 검색 결과를 LLM이 활용할 수 있는 Guideline Context로 구성하였다.

전체 처리 과정은 그림 19와 같다.




그림 19. Clinical Guideline 검색 및 Context 구성 과정

(1) 질문 Embedding 및 Guideline 검색

사용자의 검색용 질문(search_question)을 BAAI/bge-base-en-v1.5 모델을 이용하여 벡터로 변환한 뒤, 3.2.4에서 구축한 Qdrant의 guidelines Collection에서 코사인 유사도가 높은 임상 진료지침 Chunk를 검색하였다.

Guideline 검색은 Concept Set이나 지식 그래프 탐색 결과를 별도의 필터로 사용하지 않고 질문 전체의 의미를 기준으로 독립적으로 수행하였다. 이를 통해 질문에 포함된 여러 임상 조건을 전체적으로 반영하여 관련 진료지침을 검색하도록 구성하였다. 실제 파이프라인에서는 관련도 점수가 높은 상위 3개의 Guideline Chunk를 최종 검색 결과로 사용하였다.

표 18. 임상 진료지침 검색 설정

항목	구현 내용
검색 방식	Embedding 기반 Vector Search
Embedding Model	SentenceTransformer (BAAI/bge-base-en-v1.5)
Vector DB	Qdrant
Collection	guidelines
Query	검색용 질문(search_question)
Embedding	정규화된 Sentence Embedding
최종 검색 수	Top-3 Guideline Chunks

(2) Guideline Search 검증

구축한 Guideline Search가 서로 다른 형태의 의료 질문에서도 관련 임상 진료지침을 검색할 수 있는지 확인하기 위해 특정 임상 기준을 묻는 질의, 약물의 사용 및 관리 조건을 묻는 질의, 여러 임상 조건이 결합된 복합 질의를 이용하여 검색 결과를 검증하였다. 검증에 사용한 질문과 주요 검색 결과는 표 19와 같다.

표 19. 질문 유형에 따른 Clinical Guideline 검색 검증 결과

질의 유형	검증 질문	주요 검색 결과
임상 기준 질의	<i>What is the target blood pressure for adults with hypertension?</i>	NICE와 WHO의 Hypertension Guideline에서 혈압 목표와 관련된 Section이 상위 검색됨
약물 사용·관리 질의	<i>When should metformin be used?</i>	Metformin의 초기 치료 조건과 금기사항을 다루는 Guideline Chunk가 상위 검색됨
복합 임상 질의	Type 2 Diabetes, CKD, Metformin 복용 및 신장 기능 모니터링 조건을 포함한 질문	당뇨병성 합병증의 선별·관리 및 Metformin 금기와 관련된 Section이 상위 검색됨

첫 번째 질문에서는 NICE와 WHO의 고혈압 진료지침에서 혈압 목표와 관련된 내용이

상위 검색되어, 구체적인 임상 기준이나 목표 수치를 묻는 질문에서도 관련 권고를 검색할 수 있음을 확인하였다. 두 번째 질문에서는 Metformin의 초기 치료 조건과 금기사항을 다루는 내용이 검색되어, 약물의 사용 시점이나 관리 조건과 관련된 질문에도 Guideline Search를 적용할 수 있음을 확인하였다.

또한 여러 임상 조건이 함께 포함된 복합 질문에서도 Type 2 Diabetes의 합병증 관리와 Metformin의 금기사항에 관련된 Section이 상위 검색되었다. 이를 통해 Guideline Search가 단순한 특정 질환명이나 약물명의 일치뿐 아니라, 여러 의료 조건이 결합된 문장형 질문에서도 질문 전체의 의미를 바탕으로 관련 임상 진료지침을 검색할 수 있음을 확인하였다.

```

Organization : NICE
Disease      : Hypertension
Chunk ID     : 16
Section      : Quality statement 4: Blood pressure targets > Quality statement

# Quality statement 4: Blood pressure targets
## Quality statement
Adults with hypertension have a blood pressure target set that is appropriate for
their age and whether blood pressure is measured in clinic or by ambulatory or home
monitoring.

Organization : WHO
Disease      : Hypertension
Chunk ID     : 27
Section      : 3 Recommendations > 3.6 Target blood pressure > RECOMMENDATION 6. TARGET BLOOD PRESSURES

## 3.6 Target blood pressure
### RECOMMENDATION 6. TARGET BLOOD PRESSURES
WHO recommends a target blood pressure treatment goal of <140/90 mmHg in all patients
with hypertension without comorbidities. (Strong recommendation, moderate-certainty
evidence)
WHO recommends a target systolic blood pressure treatment goal of <130 mmHg in patients
with hypertension and known cardiovascular disease (CVD). (Strong recommendation,
moderate-certainty evidence)
WHO suggests a target systolic blood pressure treatment goal of <130 mmHg in high-risk
patients with hypertension (those with high CVD risk, diabetes mellitus, chronic
kidney disease). (Conditional recommendation, moderate-certainty evidence)

```

(a) HTN 혈압 목표 관련 검색 결과

```

Organization : WHO
Disease      : Type 2 Diabetes
Chunk ID     : 33
Section      : 2 Management of diabetes > Pharmacological management > Control of
blood glucose levels (glycaemia) > Initial treatment:

## Pharmacological management
### Control of blood glucose levels (glycaemia)
#### Initial treatment:
- Metformin does not cause weight gain or hypoglycaemia and is the recommended initial
treatment for people who do not achieve the desired glycaemic control with diet and
physical activity. Increase the dosage gradually according to the diabetes protocol.
- A second-generation sulfonylurea (preferably gliclazide) can be used as initial
(first-line) treatment when metformin is contraindicated or not tolerated. Sulfonylureas
may cause weight gain or hypoglycemia.
- Other pharmacological agents have not been shown to be superior to metformin or
sulfonylurea for glycaemic control and long-term outcomes as initial treatment.

Organization : WHO
Disease      : Type 2 Diabetes
Chunk ID     : 34
Section      : 2 Management of diabetes > Pharmacological management > Control of
blood glucose levels (glycaemia) > Contraindications to metformin

#### Contraindications to metformin
Do not use metformin in people with any of the following:
- Chronic kidney disease with estimated glomerular filtration rate (eGFR) <30 mL/min/1.73 m²
- Severe liver dysfunction
- Acute cardiac insufficiency
- Respiratory insufficiency
- Alcohol abuse
- History of lactic acidosis

```

(b) Metformin 사용 및 금기 관련 검색 결과

그림 20. 질문 유형에 따른 Clinical Guideline 검색 검증 결과

(3) Guideline Chunk 검색 결과

실제 MedicalQA 파이프라인에서 Qdrant 검색 결과는 관련도 점수와 함께 Guideline의 발행 기관, 대상 질환, Section 및 본문 정보를 반환한다. 다음은 3장에서 지속적으로 사용한 COPD 급성 악화 예시 질문에 대해 검색된 Top-3 Guideline Chunk이다.

검색 결과, NICE의 Chronic Obstructive Pulmonary Disease 진료지침 가운데 급성 악화

시 응급 산소 투여와 관련된 내용이 상위에 검색되었다. 검색된 Chunk에는 급성 악화 환자의 산소포화도를 88%~92% 범위로 유지하도록 조절된 산소 치료를 시행해야 한다는 권고와, 조절되지 않은 산소 투여로 인해 이산화탄소 농도가 증가하고 혈액 pH가 감소하여 산증이 발생할 수 있다는 내용이 포함되어 있었다.

	score	organization	disease	text
0	0.802563	NICE	Chronic Obstructive Pulmonary Disease (COPD)	## Rationale ¶During an exacerbation, people...
1	0.776494	NICE	Chronic Obstructive Pulmonary Disease (COPD)	# Quality statement 6: Emergency oxygen during...
2	0.758416	NICE	Chronic Obstructive Pulmonary Disease (COPD)	### Process ¶Proportion of people receiving ...

그림 21. 사용자 질문에 대한 Clinical Guideline 검색 결과

(4) Guideline Context 구성

검색된 Top-3 Guideline Chunk는 관련도 점수, 본문, 발행 기관, 대상 질환 및 문서의 제목 계층 정보 등 여러 필드로 구성되어 있으므로, 이를 그대로 LLM에 전달하지 않고 일정한 형식의 Guideline Context로 변환하였다.

각 Chunk는 발행 기관(Organization)과 대상 질환(Disease) → 문서 내 Section → 검색된 본문(Text) 순서로 정리하였다. Section 정보는 3.2.4에서 Chunking 과정에 부여한 h1~h4 Metadata를 이용하여 상위 제목에서 하위 제목으로 이어지는 계층 구조로 표현하였다. 이를 통해 LLM이 검색된 문장의 내용뿐 아니라 해당 내용이 어떤 기관의 어떤 질환 지침에서, 어느 Section에 제시된 내용인지 함께 확인할 수 있도록 하였다.

최종적으로 검색된 세 개의 Chunk를 하나의 Guideline Context로 결합하였으며, 생성된 Context는 Graph Context와 함께 최종 답변 생성 Prompt에 입력하였다. 또한 검색된 Guideline의 원문과 출처 정보는 최종 응답 데이터에도 포함하여, 사용자가 웹서비스의 근거 보기 기능을 통해 답변 생성에 활용된 임상 진료지침을 직접 확인할 수 있도록 하였다.

표 20. Guideline Context 구성 요소

구성 요소	역할
Organization	Guideline 출처 기관
Disease	대상 질환
Section	Guideline 문서 내 위치
Text	검색된 임상 진료지침 내용

3.3.5. 근거 기반 답변 생성

3.3.3에서 생성한 Graph Context와 3.3.4에서 생성한 Guideline Context를 사용자 질문과 함께 Prompt에 구성하여 최종 답변을 생성하였다. Prompt는 검색 근거의 역할과 활용 원칙을 정의하는 System Prompt와 실제 질문 및 검색 Context를 포함하는 User Prompt로 구성되며, 생성된 Prompt는 Gemma4:12b 모델에 전달된다.

최종 답변 생성을 위한 기반 LLM은 Gemma4:12b를 사용하였다[14]. 로컬 환경에서 모델을 실행하고 FastAPI 기반 백엔드에서 호출하기 위해 Ollama를 활용하였다. 개발 환경의 GPU 자원을 고려하여 26B급 모델보다 메모리 부담이 낮은 12B 모델을 선택하였으며, Q4_K_M 양자화 모델을 사용하여 모델 실행에 필요한 자원과 생성 성능 사이의 균형을 고려하였다.

답변 생성 후에는 별도의 Translation Prompt를 이용하여 질문과 답변을 한국어로 변환하고, 생성된 답변과 번역 결과, 검색된 지식 그래프 및 임상 진료지침 정보를 최종 API 응답으로 반환하도록 구현하였다. 전체 처리 과정은 그림 22와 같다.




그림 22. 검색 근거 기반 최종 답변 생성 과정

(1) Context를 이용한 Answer Prompt 구성

최종 답변 생성을 위해 사용자 질문과 Graph Context, Guideline Context를 하나의 Prompt로 구성하였다. Prompt는 답변 생성 전반에 적용되는 원칙을 정의하는 System Prompt와 실제 사용자 질문 및 검색된 근거 정보를 전달하는 User Prompt로 구분하였다.

System Prompt에서는 두 검색 근거의 역할을 명확히 구분하였다. Graph Context는 질병, 증상, 약물, 검사 등 의료 개념 사이의 구조적인 관계를 설명하는 근거로 활용하고, Clinical Guideline은 치료, 선별, 모니터링, 진단 기준, 목표 수치 및 금기 사항과 같이 실제 임상 의사결정에 필요한 권고 정보를 제공하는 근거로 활용하도록 구성하였다.

표 219. 최종 답변 생성 Prompt의 구성 요소

구성 요소	내용
Question	사용자의 질문
Graph Context	지식 그래프에서 검색한 의료 개념 간 관계 정보
Clinical Guideline	임상 진료지침 검색을 통해 확보한 권고 및 근거 정보

User Prompt는 ## Question, ## Graph Context, ## Clinical Guideline, ## Answer의 고정된 구성을 사용하여 LLM이 사용자 질문과 두 종류의 검색 근거를 명확하게 구분할 수 있도록 하였다. 특정 Context가 검색되지 않은 경우에도 Prompt 구조를 유지하고, 해당 근거가 없음을 명시하도록 구성하였다.

(2) 근거 기반 답변 생성

구성된 System Prompt와 User Prompt를 Gemma4:12b 모델에 전달하여 최종 답변을 생성하였다. 모델은 Ollama를 통해 호출하였으며, 답변 생성에는 표 22와 같은 설정을 적용하였다.

표 2210. 답변 생성 모델 설정

항목	설정
LLM	Gemma4:12b
양자화	Q4_K_M
실행 방식	Ollama Client.chat()
Temperature	0.1
최대 생성 Token	1,024
Thinking Mode	False

의료 질의응답에서는 표현의 다양성보다 동일한 질문과 검색 근거에 대해 안정적이고 일관된 답변을 생성하는 것이 중요하다고 판단하여 Temperature를 0.1로 설정하였다.

답변 생성 시에는 검색된 정보를 단순히 나열하는 것이 아니라, System Prompt에 정의된 근거 활용 원칙에 따라 사용자 질문과 관련된 정보를 선택하여 답변에 반영하도록 구성하였다.

(3) 근거 활용 및 충돌 처리

Graph Context와 Clinical Guideline은 서로 다른 성격의 의료 정보를 제공하므로, System Prompt에 두 근거의 선택적 활용 및 충돌 처리 원칙을 명시하였다.

먼저 검색된 정보를 모두 답변에 포함하지 않고, 사용자 질문에 실제로 필요한 정보만 선택적으로 활용하도록 하였다. Graph Context를 사용하는 경우에는 제공된 의료 개념과 관계를 벗어나 새로운 인과관계를 임의로 생성하지 않도록 제한하였으며, Clinical Guideline을 활용할 때에는 해당 권고의 발행 기관과 내용을 구분하여 제시하도록 하였

다.

두 근거가 모두 질문과 관련된 정보를 제공하는 경우에는 Graph Context를 의료 개념 간 관계를 설명하는 데 활용하고, Clinical Guideline을 구체적인 치료·검사·관리 기준을 제시하는 데 활용하도록 하였다. 두 근거가 동일한 임상적 판단에 대해 상충하는 경우에는 실제 임상 권고 문서인 Clinical Guideline을 우선하도록 하였다. 또한 NICE와 WHO 등 서로 다른 기관의 Guideline이 상이한 권고를 제시하는 경우에는 하나의 권고를 임의로 선택하지 않고 각 기관의 권고 차이를 함께 명시하도록 구성하였다.

표 2311. 검색 근거 활용 원칙

상황	답변 생성 방식
Graph와 Guideline 모두 관련 정보 존재	각 근거의 역할에 따라 관련 정보를 통합하여 활용
Graph와 Guideline 내용이 충돌	Clinical Guideline을 우선적으로 활용
서로 다른 기관의 Guideline이 충돌	각 기관의 권고 차이를 답변에 명시
Guideline 출처 기관을 확인할 수 있음	해당 권고의 기관명을 함께 제시
검색 Context가 충분하지 않음	일반 의료 지식을 보완적으로 사용할 수 있으나 검색 근거에서 확인된 사실처럼 표현하지 않음

검색된 Context만으로 질문에 필요한 정보를 충분히 제공하기 어려운 경우에는 LLM의 일반 의료 지식을 보완적으로 활용할 수 있도록 하였다. 다만 이러한 내용은 Graph Context나 Clinical Guideline에서 직접 확인된 근거인 것처럼 표현하지 않도록 제한하였다. 이를 통해 검색 결과가 답변의 초점을 불필요하게 변경하거나, 제공된 근거를 넘어선 내용을 확립된 사실처럼 제시하는 것을 줄이고자 하였다.

(4) 한국어 답변 변환 및 최종 결과 반환

본 시스템에서 활용하는 SNOMED CT, RxNorm, LOINC의 표준 의료 용어체계와 NICE, WHO의 임상 진료지침이 모두 영어 기반 자원이므로, 의료 개념 검색과 임상 진료지침 검색 및 답변 생성 과정은 영어를 기준으로 수행하였다. 다만 한국어 사용자도 생성된 답변을 확인할 수 있도록, Gemma4:12b에서 생성된 영어 질문과 답변을 별도의 Translation Prompt를 통해 한국어로 변환하도록 구현하였다.

Translation Prompt에는 영어 질문과 생성된 영어 답변을 함께 입력하고, 원문의 의미와 내용을 유지하면서 자연스러운 한국어로 변환하도록 지시하였다. 특히 질환명, 약물명, 검사명 등 주요 의료 전문 용어는 가능한 경우 한국어 명칭과 원래 영어 표현을 함께 표시하도록 하였다. 예를 들어 eGFR은 추정 사구체 여과율(eGFR), Metformin은 메트포르민(Metformin)과 같은 형식으로 변환한다. 또한 의료 약어와 NICE·WHO와 같은 Guideline 발행 기관명, SNOMED CT·RxNorm·LOINC와 같은 고유 명칭은 필요한 경우 원문 표현을 유지하도록 하였다.

번역 과정에서 원문의 의료적 의미가 변경되지 않도록 내용을 임의로 요약하거나 새로운 정보를 추가·삭제하지 않도록 제한하였다. 답변 생성 단계와 달리 번역에서는 표현의 다양성보다 원문 재현성이 중요하므로 Temperature를 0, Thinking Mode를 False로 설정하였다. 답변 생성과 번역에는 동일한 Gemma4:12b 모델을 사용하되, 각 작업의 목적에 맞게 생성 설정을 달리 적용하였다.

표 24. 한국어 변환 단계의 LLM 설정

항목	설정
LLM	Gemma4:12b
Temperature	0
최대 생성 Token	2,048
Thinking Mode	False

번역 결과는 이후 시스템에서 질문과 답변을 안정적으로 구분하여 추출할 수 있도록 다음과 같은 고정된 태그 형식으로 출력하였다.

<QUESTION_KO> 한국어 질문</QUESTION_KO>
<ANSWER_KO> 한국어 답변</ANSWER_KO>

시스템은 해당 태그에서 한국어 질문과 답변을 추출하여 최종 API 응답에 포함한다. 최종 응답에는 원본 질문(question), 대화 이력을 반영한 재작성 질문(rewritten_question), 영어 답변(answer), 한국어 질문 및 답변(question_ko, answer_ko)과 함께 검색 과정에서 생성된 지식 그래프(graph), 의료 표현(mentions), Concept Set(concept_set), 임상 진료지침(guidelines) 및 채팅 식별자(chat_id)를 반환한다.

실제 COPD 급성 악화 예시 질문에 전체 파이프라인을 적용한 결과, 지식 그래프에서는

COPD 및 급성 악화 관련 의료 개념의 계층 관계와 치료 약물 관계가 Graph Context로 구성되었으며, Roflumilast, Acclidinium bromide, Revefenacin, Ensifentrine 등의 약물 정보가 답변 생성에 제공되었다. Clinical Guideline 검색에서는 NICE의 COPD 진료지침에서 급성 악화 시 산소포화도를 88%~92%로 유지하도록 하는 산소 치료 권고와, 과도한 산소 투여에 따른 이산화탄소 증가 및 산증 위험에 관한 내용이 검색되었다.

최종적으로 Gemma4:12b는 이러한 지식 그래프 기반의 질환·약물 관계와 임상 진료지침 기반의 산소 관리 기준을 사용자 질문과 함께 활용하여 COPD 급성 악화 시 고려해야 할 합병증, 치료 약물 및 산소 상태 모니터링에 대한 답변을 생성하였다. 그림 23은 해당 질문에 대한 최종 답변 생성 결과를 나타낸다.

QUESTION

For a patient with COPD experiencing an acute exacerbation, what COPD-related complications should be considered, which medications can be used for treatment, and how should oxygen status be monitored?

ANSWER

For a patient with chronic obstructive pulmonary disease (COPD) experiencing an acute exacerbation, the clinical management involves monitoring for specific complications, utilizing appropriate medications, and strictly controlling oxygen therapy.

Complications to Consider

During an acute exacerbation of COPD, patients may experience:

- * ****Worsening Gas Exchange:**** This can lead to low blood oxygen levels (hypoxemia).
- * ****Respiratory Acidosis:**** It is critical to monitor for uncontrolled oxygen therapy, which can reduce the depth and frequency of breathing. This may cause a rise in blood carbon dioxide levels and a subsequent fall in blood pH (acidosis).

Medications for Treatment

Based on the provided clinical data, several medications are associated with the treatment of COPD:

- * ****Roflumilast**** (Brand names: Daliresp, Zoryve)
- * ****Acclidinium bromide**** (Brand names: Tudorza, Duaklir)
- * ****Revefenacin**** (Brand name: Yupelri)
- * ****Ensifentrine**** (Brand name: Ohtuvayre)

Oxygen Monitoring and Management

According to the NICE guidelines, oxygen therapy during an acute exacerbation must be carefully controlled:

- * ****Target Saturation:**** For patients receiving emergency oxygen for an acute exacerbation of COPD, the goal is to maintain oxygen saturation levels between ****88% and 92%****.
- * ****Delivery Method:**** To avoid the risks associated with uncontrolled oxygen (such as increased carbon dioxide levels), therapy should be administered using a delivery device at a flow rate specifically calibrated to maintain the target saturation range.

그림 23. GraphRAG 및 Clinical Guideline 기반 답변 생성 결과

3.4. 웹서비스 구현


MedicalQA를 사용자가 웹 환경에서 편리하게 이용할 수 있도록 React와 Vite 기반의 웹서비스를 구현하였다. 웹서비스는 의료 질문과 답변을 주고받는 채팅 인터페이스와 생성된 답변의 지식 그래프 및 임상 진료지침 근거를 확인하는 기능을 중심으로 구성하였다.

3.4.1. 사용자 인터페이스


프론트엔드는 React와 Vite를 이용하여 구현하였으며, 메인 화면과 채팅 화면을 중심으로 사용자 인터페이스를 구성하였다. 사용자는 의료 질문을 입력하고 생성된 답변을 대화 형태로 확인할 수 있으며, 기존 대화를 다시 불러오거나 새로운 채팅을 생성할 수 있다. 주요 구현 기능은 표 25에 정리하였다.

표 25. 사용자 인터페이스

구분	구현 내용
메인 화면	서비스 안내, 지원 질환 표시 및 의료 질문 입력
질문 입력	사용자의 의료 질문 입력 및 전송
채팅 화면	사용자 질문과 AI 답변을 대화 형태로 표시
답변 출력	Markdown 기반 AI 답변 렌더링
번역 기능	질문 및 답변의 원문과 한국어 번역 전환
근거 보기	AI 답변 생성에 활용된 임상 진료지침 및 지식 그래프 확인
새 채팅	새로운 대화 세션 시작
채팅 목록	저장된 기존 채팅 목록 조회
대화 복원	기존 채팅 선택 시 이전 질문 및 답변 불러오기
채팅 관리	채팅 제목 변경 및 삭제



(a) 메인 화면



(b) 채팅 화면

그림 24. MedicalQA 웹서비스 메인 및 채팅 화면

그림 24는 구현된 MedicalQA의 메인 화면과 채팅 화면을 나타낸다. 사용자는 좌측 채팅 목록을 통해 기존 대화를 선택하거나 새로운 대화를 시작할 수 있으며, 화면 하단의 입력창을 통해 의료 질문을 전송할 수 있도록 구성하였다.

3.4.2. 답변 근거 표시

MedicalQA에서는 생성된 답변에 활용된 정보를 사용자가 직접 확인할 수 있도록 답변 근거 표시 기능을 구현하였다. 사용자는 AI 답변 하단의 근거 보기 버튼을 선택하여 검색된 임상 진료지침과 지식 그래프를 확인할 수 있다.




그림 25. AI 답변 화면 및 근거 보기 버튼

그림 25는 AI 답변 화면과 근거 보기 버튼을 나타낸다. 답변 하단에는 한국어 번역 보기 기능과 근거 보기 기능을 배치하여, 사용자가 답변과 관련 근거를 필요에 따라 확인할 수 있도록 구성하였다.




그림 26. 임상 진료지침 근거 표시 화면

근거 보기 화면에서는 먼저 답변 생성 과정에서 검색된 임상 진료지침을 제공한다. 그림 26과 같이 각 진료지침은 카드 형태로 표시되며, 기관명, 질환명, 관련 Section 및 본문 내용을 함께 확인할 수 있다.




그림 27. 지식 그래프 근거 표시 화면

또한 검색된 의료 개념과 관계는 지식 그래프(Knowledge Graph) 형태로 시각화하였다. 지식 그래프에서는 Root Concept과 SNOMED CT, RxNorm, LOINC 기반 개념을 구분하여 표시하고, 각 개념 사이의 관계를 연결선으로 표현하였다. 이를 통해 사용자는 답변 생성에 활용된 의료 개념과 개념 간 연관 관계를 시각적으로 확인할 수 있다.

이와 같이 MedicalQA는 생성된 답변과 함께 검색된 임상 진료지침 및 지식 그래프 정

보를 제공하여, 사용자가 답변에 활용된 근거 정보를 직접 확인할 수 있도록 구현하였다.

3.5. 시스템 설계

MedicalQA는 프론트엔드, 백엔드, 데이터베이스, 의료 지식 저장소 및 LLM 실행 환경을 독립적인 구성요소로 분리하고, 각 서비스가 상호 연동되는 구조로 설계하였다. 또한 Docker 기반 실행 환경을 구성하여 각 서비스를 통합적으로 관리할 수 있도록 하였다.

3.5.1. 시스템 구조




그림 28. MedicalQA 전체 시스템 구조

그림 28은 MedicalQA의 전체 시스템 구조를 나타낸다. 사용자는 React 기반 프론트엔드를 통해 의료 질문을 입력하며, 프론트엔드는 FastAPI 기반 백엔드와 REST API를 통해 데이터를 주고받는다.

백엔드는 의료 질의응답 처리를 위해 Neo4j, Qdrant 및 Ollama와 연동된다. Neo4j에는 SNOMED CT, RxNorm, LOINC 기반의 의료 개념과 관계로 구성된 지식 그래프를 저장하였으며, Qdrant에는 의료 개념 검색을 위한 데이터와 임상 진료지침 데이터를 벡터 형태로 저장하였다. Ollama에서는 Gemma 모델을 실행하여 사용자 질문과 검색된 의료 정보를 기반으로 최종 답변을 생성한다.

백엔드에서는 Embedding 모델, Qdrant Client, Neo4j Driver, LLM과 같이 초기화 비용이

큰 리소스를 애플리케이션 시작 시 한 번 생성하고, 의료 개념 검색, 지식 그래프 탐색, 임상 진료지침 검색 및 답변 생성 모듈에서 공유하여 사용하도록 구성하였다. 이를 통해 동일한 모델이나 외부 서비스 연결 객체가 각 처리 단계에서 반복적으로 생성되는 것을 방지하고, 하나의 질의응답 파이프라인에서 필요한 기능을 순차적으로 실행할 수 있도록 하였다.

또한 PostgreSQL에는 채팅 정보와 메시지, 한국어 번역 결과 및 답변 근거 정보를 저장하도록 구성하였다. 각 구성요소는 Docker 컨테이너 단위로 구성하였으며, Docker Compose를 통해 통합적으로 실행할 수 있도록 설계하였다.

3.5.2. 데이터베이스

사용자의 채팅 이력과 질의응답 결과를 지속적으로 저장하기 위해 PostgreSQL 기반 데이터베이스를 구성하였다. 데이터베이스는 채팅 정보를 관리하는 Chat 테이블과 각 채팅에 포함된 메시지를 저장하는 Message 테이블로 구성하였다.

표 26. Chat 테이블 구조

필드명	설명
id	채팅 고유 ID
title	채팅 제목
created_at	채팅 생성 시간
updated_at	채팅 수정 시간

표 27. Message 테이블 구조

필드명	설명
id	메시지 고유 ID
chat_id	메시지가 속한 채팅 ID
role	메시지 작성 주체(user / assistant)
content	사용자 질문 또는 AI 답변
question_ko	사용자 질문의 한국어 번역

answer_ko	AI 답변의 한국어 번역
graph	답변 생성에 활용된 지식 그래프 데이터
guidelines	답변 생성에 활용된 임상 진료지침 데이터
created_at	메시지 생성 시간

Chat과 Message는 1:N 관계로 구성하였으며, 하나의 채팅에 여러 개의 메시지가 저장된다. 채팅 삭제 시 해당 채팅에 포함된 메시지도 함께 삭제되도록 Cascade 관계를 적용하였다.

데이터베이스 접근에는 SQLAlchemy ORM을 사용하였으며, 채팅 생성·조회·수정·삭제와 메시지 저장·조회 기능을 구현하였다. 또한 최근 대화 내용을 조회하여 후속 질문 처리 시 이전 대화 이력을 활용할 수 있도록 구성하였다.

3.5.3. REST API

프론트엔드와 백엔드 간 데이터 통신은 REST API 기반으로 구현하였다. React에서는 Fetch API를 이용하여 의료 질문 전송과 채팅 생성·조회·수정·삭제 요청을 전송하고, FastAPI 기반 백엔드에서 반환된 JSON 데이터를 화면에 반영하도록 구성하였다.

표 28. MedicalQA 웹서비스 REST API

Method	URL	기능
POST	/api/chat	의료 질문 전송 및 AI 답변 생성
POST	/api/chats	새로운 채팅 생성
GET	/api/chats	전체 채팅 목록 조회
GET	/api/chats/{chat_id}	특정 채팅 및 메시지 조회
PATCH	/api/chats/{chat_id}	채팅 제목 변경
DELETE	/api/chats/{chat_id}	채팅 삭제

의료 질의응답 요청에 사용되는 /api/chat은 현재 채팅 ID와 사용자 질문을 전달받으며, 처리 결과로 AI 답변과 번역 및 답변 근거 데이터를 반환한다.

표 29. 의료 질의응답 주요 응답 데이터

필드명	설명
chat_id	질문이 저장된 채팅 ID
question	사용자가 입력한 원본 질문
rewritten_question	대화 이력을 반영하여 재작성된 독립형 질문
answer	Gemma가 생성한 AI 답변
question_ko	사용자 질문의 한국어 번역
answer_ko	AI 답변의 한국어 번역
graph	지식 그래프 시각화를 위한 Node 및 Edge 데이터
guidelines	검색된 임상 진료지침 정보
mentions	질문에서 추출된 의료 관련 표현
concept_set	Entity Linking을 통해 선택된 의료 개념 정보

채팅 관리 API는 프론트엔드의 채팅 목록과 연동하였다. 사용자가 기존 채팅을 선택하면 저장된 메시지를 불러와 대화를 복원하며, 채팅 제목 변경 및 삭제 결과도 화면에 반영하도록 구현하였다.

3.5.4. 실행 환경

MedicalQA의 각 구성요소는 Docker 컨테이너로 분리하여 구성하였으며, Docker Compose를 이용하여 전체 서비스를 통합적으로 실행하도록 설계하였다. 이를 통해 각 서비스를 독립적으로 관리하면서 동일한 실행 환경을 유지할 수 있도록 하였다.

표 3012. Docker Compose 서비스 구성

서비스	사용 기술	주요 역할
Frontend	React, Vite	웹 사용자 인터페이스 제공
Backend	FastAPI	REST API 제공 및 웹서비스 요청 처리
PostgreSQL	PostgreSQL 17	채팅 및 메시지 데이터 저장

Neo4j	Neo4j 5 Community	의료 지식 그래프 저장 및 조회
Qdrant	Qdrant	의료 개념 및 임상 진료지침 벡터 검색
Ollama	Ollama, Gemma	LLM 기반 의료 답변 생성 및 번역

백엔드는 Docker Compose 내부 네트워크를 통해 PostgreSQL, Neo4j, Qdrant 및 Ollama와 연결되도록 구성하였다. 또한 백엔드와 Ollama에는 GPU 사용 환경을 적용하여 Gemma 모델의 추론을 수행하도록 구성하였다. 개발 환경에서는 NVIDIA RTX 2080 Ti(11GB GPU Memory)를 사용하였으며, 해당 하드웨어 자원을 고려하여 Gemma4:12b의 Q4_K_M 양자화 모델을 기반 LLM으로 사용하였다.

PostgreSQL, Neo4j, Qdrant 및 Ollama에는 Docker Volume을 적용하여 컨테이너 재시작 이후에도 데이터와 모델 정보를 유지할 수 있도록 구성하였다.

이와 같이 각 서비스를 컨테이너 단위로 분리하고 Docker Compose를 통해 통합함으로써 MedicalQA를 일관된 환경에서 실행하고 관리할 수 있도록 하였다.

4. 연구 결과 분석 및 평가

본 장에서는 구축한 MedicalQA 시스템의 성능을 평가하고 결과를 분석한다. 동일한 LLM만을 사용하는 경우와 의료 지식 그래프 및 임상 진료지침 검색을 추가한 MedicalQA를 비교하여 검색 기반 의료 정보 활용 여부에 따른 답변 정확도 차이를 분석하였다.

4.1. 정량 평가

4.1.1. 평가 방법

정량 평가는 의료 객관식 질의응답 데이터셋인 MedQA를 이용하여 수행하였다. 평가 후보 문항은 Hugging Face에서 제공되는 awinml/medqa 데이터셋의 questions 구성 중 test split을 대상으로 추출하였다.

본 연구에서 주요 질환으로 설정한 T2DM, HTN, CKD, HF, COPD와 관련된 문항을 선별하기 위해 질환별 검색어를 정의하였다. 검색어에는 각 질환의 정식 명칭뿐 아니라 약어, 동의 표현 및 해당 질환을 나타내는 주요 임상 표현을 포함하였다.

표 31. MedQA 평가 후보 추출을 위한 질환별 검색어 예시

질환	검색어 예시
T2DM	diabetes, diabetic, type 2 diabetes, T2DM, hyperglycemia, HbA1c
HTN	hypertension, hypertensive, high blood pressure, HTN, antihypertensive
CKD	chronic kidney disease, CKD, renal failure, ESRD, eGFR, albuminuria
HF	heart failure, congestive heart failure, CHF, HFrEF, HFpEF, ejection fraction
COPD	COPD, chronic obstructive pulmonary disease, emphysema, chronic bronchitis

각 MedQA 문항의 질문 본문(question)을 대상으로 질환별 검색어를 정규표현식으로 탐색하였다. 검색 시 대소문자를 구분하지 않았으며, 검색어에 단어 경계(word boundary)를 적용하여 다른 단어의 일부가 우연히 일치하는 경우를 줄였다. 하나 이상의 질환 관련 표현이 발견된 문항을 해당 질환의 후보 문항으로 추출하고, 원본 질문 ID, 대상 질환, 일치한 검색어, 질문, 선택지 A~D 및 정답 정보를 함께 저장하였다.

이 과정을 통해 252개의 고유 MedQA 문항이 후보로 추출되었다. 하나의 문항이 둘 이상의 대상 질환과 관련된 경우에는 각 질환의 평가 후보에 각각 포함하였으며, 이에 따라 질환별 분류를 기준으로 한 최종 평가 항목은 총 330건으로 구성되었다.

추출된 후보 문항은 문항의 전체 내용과 정답 결정에서 대상 질환이 차지하는 역할을 직접 검토하여 A, B, Exclude의 세 유형으로 분류하였다.

표 13. MedQA 평가 후보 추출을 위한 질환별 검색어 예시

구분	정의
A (Core Disease)	대상 질환의 진단, 병태생리, 치료, 약물, 합병증 등에 대한 지식이 정답 결정에 직접적으로 필요한 문항
B (Relevant Comorbidity)	대상 질환이 중요한 동반질환 또는 위험요인으로 등장하지만, 최종 정답은 다른 질환이나 임상 상황을 중심으로 결정되는 문항
Exclude (Irrelevant Mention)	대상 질환이 문항에 포함되어 있으나 단순 언급 수준으로, 정답 결정에 실질적인 영향을 미치지 않는 문항

각 평가 항목에 대해 동일한 MedQA 질문과 선택지를 Gemma4-only와 MedicalQA에 각각 입력하고, 두 시스템이 선택한 답을 MedQA의 정답과 비교하였다. 두 시스템은 동일한 Gemma4:12b 모델을 사용하였으며, MedicalQA에서는 추가적으로 GraphRAG 기반 지식 그래프 검색 및 임상 진료지침 검색 결과를 답변 생성에 활용하였다.

정답률은 다음과 같이 계산하였다.

$$Accuracy = \frac{\text{정답 평가 항목 수}}{\text{전체 평가 항목 수}} \times 100$$

전체 성능은 330개의 질환별 평가 항목을 기준으로 계산하였으며, 추가적으로 문항 유형별 성능과 질환 및 문항 유형에 따른 세부 성능을 비교하였다.

4.1.2. 전체 성능

총 330개의 질환별 평가 항목을 대상으로 Gemma4-only와 MedicalQA의 전체 정확도를 비교하였다. 결과는 그림 29와 표 33에 나타내었다.




표 3314. Gemma4-only와 MedicalQA의 전체 정확도 비교

구분	정답 평가 항목 수	전체 평가 항목 수	정확도
Gemma4-only	237	330	71.8%
MedicalQA	276	330	83.6%
성능 향상	+39	-	+11.8%p

평가 결과, Gemma4-only의 정확도는 71.8%였으며, MedicalQA는 83.6%의 정확도를 기록하였다. MedicalQA는 동일한 Gemma4:12b 모델을 사용하면서 39개의 평가 항목을 추가로 정확하게 답변하였으며, 전체 정확도가 11.8%p 향상되었다.

이는 본 평가 데이터에서 MedicalQA가 Gemma4-only보다 높은 정확도를 보였음을 나타낸다.

4.1.3. 문항 유형별 성능

A, B, Exclude 유형에 따라 두 시스템의 정확도를 비교한 결과는 그림 30과 표 34에 나타내었다.




표 3415. 문항 유형별 Gemma4-only와 MedicalQA 정확도 비교

구분	평가 항목 수	Gemma4-only	MedicalQA	변화
A	55	46/55 (83.6%)	48/55 (87.3%)	+3.7%p
B	92	66/92 (71.7%)	81/92 (88.0%)	+16.3%p
Exclude	183	125/183 (68.3%)	147/183 (80.3%)	+12.0%p
전체	330	237/330 (71.8%)	276/330 (83.6%)	+11.8%p

A 유형에서는 Gemma4-only와 MedicalQA가 각각 83.6%, 87.3%로 비교적 높은 정확도를 보였으며, 성능 차이는 3.7%p로 나타났다. 반면 B 유형에서는 71.7%에서 88.0%로 16.3%p 향상되어 가장 큰 성능 차이를 보였다. Exclude 유형에서도 68.3%에서 80.3%로 12.0%p 향상되었다.

특히 대상 질환이 핵심 정답 자체는 아니지만 중요한 동반질환 또는 위험요인으로 포함된 B 유형에서 두 시스템 간 정확도 차이가 가장 크게 나타났다.

4.1.4. 질환 및 문항 유형별 정확도 비교

문항 유형별 성능 차이가 각 질환에서 어떻게 나타나는지 확인하기 위해 T2DM, HTN, CKD, HF, COPD에 대해 A, B, Exclude 유형별 정확도를 세부적으로 비교하였다. 결과는 표 35와 같다.

표 3516. 질환 및 문항 유형별 정확도 비교

질환	유형	Gemma4-only	MedicalQA
T2DM	A	15/18 (83.3%)	16/18 (88.9%)
	B	28/37 (75.7%)	32/37 (86.5%)
	Exclude	48/71 (67.6%)	58/71 (81.7%)
HTN	A	16/22 (72.7%)	19/22 (86.4%)
	B	31/46 (67.4%)	42/46 (91.3%)
	Exclude	60/87 (69.0%)	67/87 (77.0%)
CKD	A	3/3 (100.0%)	2/3 (66.7%)
	B	3/3 (100.0%)	3/3 (100.0%)
	Exclude	5/10 (50.0%)	7/10 (70.0%)
HF	A	8/8 (100.0%)	7/8 (87.5%)
	B	2/4 (50.0%)	2/4 (50.0%)
	Exclude	5/8 (62.5%)	8/8 (100.0%)
COPD	A	4/4 (100.0%)	4/4 (100.0%)

	B	2/2 (100.0%)	2/2 (100.0%)
	Exclude	7/7 (100.0%)	7/7 (100.0%)

세부적으로는 HTN의 B 유형이 67.4%에서 91.3%로 크게 향상되었으며, HF의 Exclude 유형도 62.5%에서 100.0%로 향상되었다. T2DM에서도 A, B, Exclude 모든 유형에서 MedicalQA의 정확도가 증가하였다.

반면 CKD와 HF의 A 유형에서는 MedicalQA의 정확도가 일부 감소하였으며, COPD에서는 모든 유형에서 두 시스템 간 차이가 나타나지 않았다. 따라서 검색 기반 의료 정보의 활용에 따른 정확도 변화는 질환과 문항 유형에 따라 서로 다르게 나타남을 확인하였다.

다만 질환 및 문항 유형별 평가 항목 수가 균등하지 않다는 점은 결과 해석 시 고려할 필요가 있다. 질환별 평가 항목 수는 T2DM 126건, HTN 155건, CKD 16건, HF 20건, COPD 13건으로 차이가 있으며, 문항 유형별로도 A 55건, B 92건, Exclude 183건으로 구성 비율이 서로 다르다. 따라서 세부 집단별 정확도는 평가 항목 수와 데이터 구성의 영향을 받을 수 있으며, 특히 평가 항목 수가 적은 질환 및 유형의 결과를 일반화하는 데에는 한계가 있다. 향후에는 질환 및 문항 유형별 평가 항목을 보다 균형 있게 구성하여 성능을 추가로 검증할 필요가 있다.

이러한 성능 차이를 보다 구체적으로 확인하기 위해 다음 절에서는 Gemma4-only에서는 오답이었으나 MedicalQA에서는 정답으로 개선된 대표 사례를 분석한다.

4.2. 사례 분석

정량 평가 결과를 보다 구체적으로 분석하기 위해 Gemma4-only에서는 오답이었으나 MedicalQA에서는 정답으로 개선된 문항 중, 두 시스템의 판단 과정에서 차이가 명확하게 나타나는 사례를 선정하였다. 각 사례에서는 Gemma4-only의 오답 원인을 분석하고, MedicalQA에서 검색된 지식 그래프 및 임상 진료지침 정보가 답변 판단에 어떻게 활용되었는지 확인하였다.

질환별로 대표성이 높은 문항을 선정하였으며, 두 시스템 모두 높은 정확도를 보인 COPD는 대표 사례 분석에서 제외하였다.

4.2.1. T2DM 사례

질환: T2DM

문항 유형: B

정답: A. Cooling the dialysate

해당 문항은 말기신부전으로 혈액투석을 받고 있는 63세 여성이 최근 투석 후 반복적으로 어지럼증을 호소하는 상황에서, 낙상 위험을 줄이기 위한 적절한 관리 방법을 선택하는 문제이다. 환자는 22년간 당뇨병을 앓아왔으며, 투석 전 혈압은 135/80 mmHg에서 투석 후 110/55 mmHg로 감소하였다.

구분	Gemma4-only	MedicalQA
최종 답변	B. Eating heavier meals during dialysis X	A. Cooling the dialysate O
주요 판단	투석 후 저혈압을 인식했으나 식사 제공을 관리 방법으로 선택	투석 후 혈압 감소를 intradialytic hypotension으로 판단하고 dialysate cooling을 선택
핵심 관계	Hemodialysis → hypotension → meal during dialysis	Hemodialysis → intradialytic hypotension → cooling dialysate
결과	임상 상태는 파악했으나 적절한 관리 방법을 잘못 선택	투석 중 혈압 저하에 적합한 관리 방법을 선택하여 정답 도출

(1) Gemma4-only의 한계

Gemma4-only는 투석 전후의 혈압 감소와 반복적인 어지럼증을 근거로 intradialytic hypotension을 의심하였다. 따라서 환자의 주요 임상 상태 자체는 적절하게 파악하였다.

그러나 관리 방법을 선택하는 과정에서 투석 중 충분한 식사를 제공하는 것이 혈압 유지에 도움이 된다고 판단하여 B를 선택하였다. 또한 cooling dialysate를 투석 중 고혈압을 조절하는 방법으로 해석하여 정답인 A를 배제하였다.

따라서 본 사례에서 Gemma4-only의 오답은 환자의 임상 상태를 잘못 판단한 것이 아니라, intradialytic hypotension과 적절한 관리 방법 사이의 관계를 잘못 연결한 데서 발생한 것으로 분석하였다.

(2) MedicalQA의 보완

MedicalQA 역시 투석 후 발생한 혈압 저하와 어지럼증을 intradialytic hypotension으로 판단하였으나, 관리 방법에서는 Gemma4-only와 달리 Cooling the dialysate를 선택하였다. MedicalQA는 투석액의 온도를 낮추는 방법이 혈관수축을 유도하고 혈액학적 안정성을 유지하여 투석 중 혈압 저하를 완화하는 데 활용될 수 있다는 점을 근거로 판단하였다.

또한 increasing ultrafiltration은 추가적인 체액 제거로 혈압 저하를 악화시킬 수 있으며, steroid administration은 해당 상황의 일반적인 관리 방법이 아니라는 점도 함께 고려하였다.

본 사례에서 검색된 임상 진료지침은 당뇨병성 신장질환과 말기신부전에서 혈액투석이 필요하다는 배경 정보는 제공하였으나, intradialytic hypotension이나 dialysate cooling에 대한 직접적인 치료 근거는 확인되지 않았다. GraphRAG 기반 지식 그래프 검색에서도 말기신부전 및 환자의 복용 약물과 관련된 정보는 검색되었으나, Cooling the dialysate와 직접 연결되는 관계는 확인되지 않았다.

따라서 본 사례에서는 MedicalQA의 정답 개선은 확인되었으나, 검색된 지식 그래프 및 임상 진료지침 정보가 정답 선택에 직접적으로 기여하였다고 판단하기는 어렵다. 이는 검색 기반 정보가 모든 문항에서 직접적인 정답 근거로 작용하는 것은 아니며, 검색 결과의 적합성이 질의응답 성능에 중요한 요소임을 보여준다.

4.2.2. HTN 사례

질환: HTN

문항 유형: B

정답: C. Na⁺/Cl⁻ cotransporter in the membranes of epithelial cells in the distal convoluted tubule

해당 문항은 고혈압과 고지혈증으로 약물 치료를 받고 있는 45세 남성이 최근 변비와 피로 증상을 보이는 상황에서, 해당 증상을 유발했을 가능성이 높은 약물의 세포 수준 작용 표적을 선택하는 문제이다. 선택지는 ARB, ACE inhibitor, thiazide diuretic, loop diuretic의 작용 기전을 각각 제시하고 있다.

구분	Gemma4-only	MedicalQA
최종 답변	A. Angiotensin-II receptors X	C. Na ⁺ /Cl ⁻ cotransporter O
주요 판단	변비와 피로를 calcium channel blocker의 부작용으로 판단	고혈압 치료 약물 중 thiazide 계열을 고려하고 작용 기전을 선택지와 연결
핵심 관계	Constipation → CCB → L-type calcium channel	Hypertension → thiazide 계열 약물 + thiazide의 작용 기전 → Na ⁺ /Cl ⁻ cotransporter
결과	추론한 약물 계열과 최종 선택지의 작용 기전이 불일치	검색된 치료 약물 정보와 약리 기전을 종합하여 정답 도출

(1) Gemma4-only의 한계

Gemma4-only는 환자의 변비와 피로를 근거로 calcium channel blocker(CCB)의 부작용을 우선적으로 의심하였다. 답변 과정에서도 CCB의 작용 표적이 L-type calcium channel이라고 판단하였다.

그러나 제시된 선택지에는 L-type calcium channel이 존재하지 않았으며, 최종적으로 선택한 A는 angiotensin-II receptor로 ARB의 작용 표적에 해당한다. Gemma4-only는 자신의 추론과 선택지가 일치하지 않는다는 점을 인식했음에도 다른 약물 가능성을 충분히 재검토하지 않고 A를 최종 답으로 선택하였다. 따라서 본 사례에서는 초기 판단에 고정되면서 약물 계열과 실제 작용 기전 사이의 일관성을 유지하지 못한 점이 오답의 주요 원인으로 분석되었다.

(2) MedicalQA의 보완

MedicalQA는 환자가 고혈압으로 약물 치료를 받고 있다는 정보를 바탕으로 thiazide diuretic을 주요 후보 중 하나로 고려하였다. GraphRAG 기반 지식 그래프 검색 결과에서는 그림 31와 같이 Hypertensive disorder, systemic arterial과 chlorthalidone, chlorothiazide 등 thiazide 계열 약물 사이의 관계가 확인되었다.

2. 지식 그래프(Knowledge Graph)




그림 31. HTN 대표 사례에서 검색된 고혈압-Thiazide 계열 약물 관계

임상 진료지침에서도 thiazide 및 thiazide-like agents가 ACE inhibitor/ARB, long-acting dihydropyridine CCB와 함께 고혈압의 주요 1차 치료 약물로 제시되었다.

1. 임상 진료지침(Clinical Guidelines)

WHO Hypertension

Section 3 Recommendations > 3.4 Drug classes to be used as first-line agents > Evidence and rationale

The anticipated benefits clearly outweighed the potential harms for three classes of medications: **thiazide and thiazide-like agents, ACEis/ARBs, and long-acting dihydropyridine CCBs**. The adverse events of these three classes were infrequent, usually mild, and can be managed or another agent can be substituted. The amount of BP reduction appeared to be a more major determinant of reduction in CV events than the choice between these three classes of antihypertensive medications, as was shown in several landmark trials (ALLHAT, VALUE, CAMELOT trials) (29, 30, 31). This balance of benefits and harms was not as clear for beta-blockers as a first choice for HTN management.

In terms of potential subgroups of patients that may benefit more from specific medication classes, ALLHAT (Antihypertensive and Lipid-Lowering Treatment to Prevent Heart Attack Trial) suggested greater BP reduction in individuals of African descent with chlorthalidone than lisinopril, and that stroke was significantly less likely with the diuretic than with the lisinopril in this group of patients than in those of Caucasian ethnicity (32). Other studies suggested benefit of diuretics or CCBs in patients over 65 years of age or of African descent, beta-blockers in patients with HTN who are post-myocardial infarction, ACEis/ARBs in diabetes mellitus, heart failure or kidney disease (33, 34). Diuretics were likely to be the most efficacious medications, and CCBs the least efficacious medications for the prevention of heart failure.

그림 32. HTN 대표 사례에서 검색된 고혈압 1차 치료 약물 관련 임상 진료지침

이러한 검색 결과는 환자가 복용했을 가능성이 있는 항고혈압제 중 thiazide 계열 약물을 고려할 수 있는 근거를 제공하였다. MedicalQA는 이후 thiazide diuretic의 약리 기전인 distal convoluted tubule의 Na^+/Cl^- cotransporter 억제제를 선택지와 연결하여 C를 최종 답으로 선택하였다.

본 사례는 지식 그래프와 임상 진료지침이 thiazide 계열 약물의 선택을 보완하고, LLM이 이를 세포 수준의 약리 기전과 연결하여 정답을 도출한 사례로 분석하였다.

4.2.3. CKD 사례

질환: CKD

문항 유형: Exclude

정답: C. Heat stroke

해당 문항은 폭염 속 군사 훈련 중 쓰러진 20세 여성의 원인을 판단하는 문제이다. 환자는 체온 40.3°C, 혈압 85/55 mmHg, 의식 변화, 뜨겁고 건조한 피부 및 전신 근육통을 보였으며, 차색 소변과 함께 urine dipstick에서 blood 양성이지만 현미경 검사에서는 RBC가 관찰되지 않았다. 한편 환자의 아버지는 CKD와 청력 및 시각 이상을 가지고 있어 Alport syndrome을 의심할 수 있는 가족력도 함께 제시되었다.

구분	Gemma4-only	MedicalQA
최종 답변	A. COL4A5 mutation X	C. Heat stroke O
주요 판단	가족력의 CKD, 청력·시각 이상을 Alport syndrome과 연결	고온 환경, 고체온, 의식 변화 및 피부 소견을 종합
판단 근거	CKD + hearing/vision problems → Alport syndrome → COL4A5	Heat stroke, Exertional heat stroke, Body temperature 및 주요 임상 증상 관련 개념
결과	가족력과 유전질환 단서에 집중하여 오답 선택	현재의 급성 임상 상태와 관련 의료 개념을 함께 고려하여 정답 도출

(1) Gemma4-only의 한계

Gemma4-only는 환자의 아버지가 CKD와 청력 및 시각 이상을 가지고 있다는 점에 집중하여 Alport syndrome을 의심하고 COL4A5 mutation을 선택하였다. 특히 가족력과 차색 소변을 유전성 신질환과 연결하면서 이를 현재 증상의 주요 원인으로 판단하였다.

그러나 환자는 폭염 속 강도 높은 훈련 직후 쓰러졌으며, 40.3°C의 고체온과 의식 변화, 뜨겁고 건조한 피부 등 heat stroke를 시사하는 급성 임상 소견을 보이고 있었다. 또한 dipstick에서 blood가 검출되었으나 RBC가 관찰되지 않는 소견 역시 현재의 급성 상태를 함께 고려할 필요가 있었다. 따라서 Gemma4-only는 가족력이라는 특정 단서에 판단이


집중되면서 환자의 현재 임상 상태를 충분히 종합하지 못한 것으로 분석하였다.

(2) MedicalQA의 보완

MedicalQA는 가족력에 따른 유전성 신질환 가능성보다 현재 환자에게 나타난 고온 환경 노출, 40.3°C의 고체온, 의식 변화 및 뜨겁고 건조한 피부를 주요 임상 단서로 판단하였다.


GraphRAG 기반 지식 그래프 검색 결과에서는 그림 33(a)와 같이 Heat stroke, Exertional heat stroke, Body temperature 등의 관련 의료 개념이 검색되었다. 또한 그림 33(b)에서는 문항에 제시된 임상 소견과 관련된 Mental state finding, Hot skin, Porter colored urine, Urine color abnormal 등의 개념이 함께 확인되었다.

2. 지식 그래프(Knowledge Graph)



(a) Heat stroke 및 Body temperature 관련 개념

2. 지식 그래프(Knowledge Graph)



(b) 주요 임상 증상 및 소변 색 관련 개념

그림 33. CKD 대표 사례에서 검색된 주요 지식 그래프

MedicalQA는 이러한 관련 의료 개념과 환자의 급성 임상 소견을 함께 고려하여 Heat stroke를 최종 답으로 선택하였다.

반면 본 사례에서 검색된 임상 진료지침은 고혈압 및 당뇨병성 신장질환의 검사와 관련된 내용으로, Heat stroke 판단을 직접적으로 뒷받침하는 근거는 확인되지 않았다. 따라서 본 사례에서는 GraphRAG 기반 지식 그래프 검색을 통해 제공된 관련 의료 개념이 답변 판단을 보완한 사례로 분석하였다.

4.2.4. HF 사례

질환: HF

문항 유형: Exclude

정답: B. Lisinopril

해당 문항은 최근 STEMI 치료를 받은 67세 남성에게 가장 큰 사망률 감소 효과를 제공하는 약물을 선택하는 문제이다. 환자는 고혈압과 말초혈관질환의 병력이 있으며, 혈압은 167/118 mmHg로 매우 높고 jugular venous distention과 bilateral pitting edema 등의 심부전 징후를 보였다. Echocardiography에서 ejection fraction은 55%였다.

구분

Gemma4-only

MedicalQA

최종 답변	C. Metoprolol succinate X	B. Lisinopril O
주요 판단	최근 STEMI와 beta-blocker의 mortality benefit에 집중	STEMI와 함께 severe hypertension 및 heart failure signs를 종합
핵심 관계	STEMI → beta-blocker → metoprolol	Hypertension → lisinopril / HF → ACE inhibitor-ARB
결과	일반적인 post-MI 치료 관계에 집중하여 오답 선택	약물-질환 관계와 동반질환별 치료 근거를 종합하여 정답 도출

(1) Gemma4-only의 한계

Gemma4-only는 최근 STEMI 이후 beta-blocker가 사망률을 감소시킨다는 점에 집중하여 Metoprolol succinate를 선택하였다. 답변에서도 post-MI 환자에서 beta-blocker의 심근 산소 요구량 감소, 부정맥 예방 및 심실 재형성 억제 효과를 주요 근거로 제시하였다.

그러나 혈압 167/118 mmHg의 심한 고혈압과 JVD, 양측 하지부종 등 현재 나타나는 심부전 징후는 충분히 반영되지 않았다. 즉, 최근 STEMI와 beta-blocker 사이의 일반적인 치료 관계에 판단이 집중되면서 환자가 동시에 가지고 있는 임상 조건의 중요성이 상대적으로 낮게 평가되었다.

(2) MedicalQA의 보완

MedicalQA는 최근 STEMI뿐 아니라 severe hypertension과 heart failure signs를 함께 고려하였다. GraphRAG 기반 지식 그래프 검색 결과에서는 그림 34와 같이 Hypertensive disorder, systemic arterial과 Lisinopril 사이의 약물 관계가 확인되었다.

2. 지식 그래프(Knowledge Graph)




그림 34. HF 대표 사례에서 검색된 고혈압-Lisinopril 약물 관계

임상 진료지침 검색 결과에서도 동반질환에 따른 약물 선택과 관련하여 post-myocardial infarction 환자에서는 beta-blocker가, heart failure 환자에서는 ACE inhibitor 또는 ARB가 유용할 수 있음이 제시되었다.

WHO
Hypertension

Section
3 Recommendations > 3.4 Drug classes to be used as first-line agents > Evidence and rationale

The anticipated benefits clearly outweighed the potential harms for three classes of medications: thiazide and thiazide-like agents, ACEis/ARBs, and long-acting dihydropyridine CCBs. The adverse events of these three classes were infrequent, usually mild, and can be managed or another agent can be substituted. The amount of BP reduction appeared to be a more major determinant of reduction in CV events than the choice between these three classes of antihypertensive medications, as was shown in several landmark trials (ALLHAT, VALUE, CAMELOT trials) (29, 30, 31) . This balance of benefits and harms was not as clear for beta-blockers as a first choice for HTN management.

In terms of potential subgroups of patients that may benefit more from specific medication classes, ALLHAT (Antihypertensive and Lipid-Lowering Treatment to Prevent Heart Attack Trial) suggested greater BP reduction in individuals of African descent with chlorthalidone than lisinopril, and that stroke was significantly less likely with the diuretic than with the lisinopril in this group of patients than in those of Caucasian ethnicity (32) . Other studies suggested benefit of diuretics or CCBs in patients over 65 years of age or of African descent, **beta-blockers in patients with HTN who are post-myocardial infarction, ACEis/ ARBs in diabetes mellitus, heart failure or kidney disease** (33, 34) . Diuretics were likely to be the most efficacious medications, and CCBs the least efficacious medications for the prevention of heart failure.

그림 35. HF 대표 사례에서 검색된 동반질환별 약물 선택 관련 임상 진료지침

MedicalQA는 지식 그래프에서 제공된 Hypertension-Lisinopril 관계와 임상 진료지침에서 제공된 Heart failure-ACEi/ARB 치료 근거를 환자의 현재 임상 상태와 종합하여 ACE inhibitor인 Lisinopril을 선택하였다. 본 사례는 여러 임상 조건이 동시에 존재하는 상황에서 구조화된 약물-질환 관계와 임상 진료지침이 LLM의 판단을 보완한 사례로 볼 수 있다.

5. 결론 및 향후 연구 방향

5.1. 결론

5.1.1. 의료 지식 검색 및 근거 기반 답변 생성

본 연구에서는 SNOMED CT, RxNorm, LOINC를 통합한 의료 지식 그래프를 구축하고, GraphRAG 기반으로 사용자 질문과 관련된 질환·약물·검사 정보를 탐색하는 MedicalQA 시스템을 구현하였다. 또한 임상 진료지침을 검색하여 생성한 Guideline Context를 Graph Context와 함께 Gemma4:12b에 제공함으로써, 의료 개념 간 구조적 관계와 실제 임상 권고를 함께 활용하여 답변을 생성하도록 구성하였다.

5.1.2. 답변 근거를 제공하는 웹서비스 구현

React와 FastAPI를 기반으로 MedicalQA 웹서비스를 구현하였다. 사용자는 의료 질문과 답변, 한국어 번역 결과를 확인할 수 있으며, 답변 생성에 활용된 임상 진료지침과 지식 그래프를 근거 정보로 직접 확인할 수 있도록 하였다.

5.1.3. 의료 질의응답 성능 평가 결과

252개의 고유 MedQA 문항에서 구성한 총 330개의 평가 항목을 이용하여 Gemma4-only와 MedicalQA를 비교하였다. Gemma4-only의 정확도는 71.8%, MedicalQA는 83.6%로 나타나 11.8%p 향상되었으며, B 유형에서는 71.7%에서 88.0%로 16.3%p 향상되어 가장 큰 차이를 보였다.

이를 통해 GraphRAG와 임상 진료지침을 이용한 외부 의료 정보 검색이 LLM 기반 의료 질의응답 성능을 보완할 수 있음을 확인하였다. 다만 일부 질환 및 문항 유형에서는 성능 향상이 제한적이거나 감소한 경우도 있어, 검색 결과의 적합성이 최종 성능에 중요한 영향을 미치는 것으로 나타났다.

5.2. 향후 연구 방향

5.2.1. 임상 진료지침 범위 확대

현재 의료 지식 그래프의 HAS_DRUG와 HAS_TEST 관계 및 임상 진료지침은 주요 5개 질환을 중심으로 구성되어 있다. 특히 HAS_TEST는 약물 정보를 매개로 연결되어 있어 검사 관계의 범위가 제한적이다.

향후에는 대상 질환과 약물·검사 매핑 범위를 확대하고 UMLS의 추가 어휘 및 매핑 정보를 활용하여 지식 그래프의 커버리지를 높일 필요가 있다. 또한 임상 진료지침의 대상 질환과 출처를 확대하여 보다 다양한 질문에 직접적인 근거를 제공할 수 있도록 개선할 필요가 있다.

5.2.2. 평가 데이터 확대 및 균형화

현재 평가 데이터는 질환별 및 문항 유형별 평가 항목 수가 균등하지 않다. 향후에는 평가 항목 수를 보다 균형 있게 구성하고 전체 평가 규모를 확대하여 MedicalQA의 성능을 보다 객관적으로 검증할 필요가 있다.

5.2.3. 고성능 LLM 적용

현재 기반 LLM으로 Gemma4:12b를 사용하였다. 향후에는 동일한 검색 파이프라인에 더 높은 추론 및 문맥 이해 능력을 가진 LLM을 적용하여, 기반 모델의 성능 차이가 최종 의료 질의응답 정확도에 미치는 영향을 비교할 필요가 있다.

6. 참고 문헌

- [1] S. Robertson and H. Zaragoza, "The Probabilistic Relevance Framework: BM25 and Beyond," *Foundations and Trends in Information Retrieval*, Vol. 3, No. 4, pp. 333-389, 2009.
- [2] H. Han et al., "Retrieval-Augmented Generation with Graphs (GraphRAG)," *arXiv preprint arXiv:2501.00309*, 2025.
- [3] S. Xiao, Z. Liu, P. Zhang, N. Muennighoff, D. Lian, and J. Nie, "C-Pack: Packed Resources for General Chinese Embeddings," *Proc. of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval*, pp. 641-649, 2024.
- [4] N. Reimers and I. Gurevych, "Sentence-BERT: Sentence Embeddings Using Siamese BERT-Networks," *Proc. of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pp. 3982-3992, 2019.
- [5] National Institute for Health and Care Excellence. (2026). *Type 2 diabetes in adults* [Online]. Available: <https://www.nice.org.uk> (downloaded 2026, June. 11)
- [6] National Institute for Health and Care Excellence. (2015). *Hypertension in adults* [Online]. Available: <https://www.nice.org.uk> (downloaded 2026, June. 11)

-
- [7] National Institute for Health and Care Excellence. (2023). *Chronic obstructive pulmonary disease in adults* [Online]. Available: <https://www.nice.org.uk> (downloaded 2026, June. 11)
- [8] National Institute for Health and Care Excellence. (2017). *Chronic kidney disease in adults* [Online]. Available: <https://www.nice.org.uk> (downloaded 2026, June. 11)
- [9] National Institute for Health and Care Excellence. (2025). *Chronic heart failure in adults: diagnosis and management* [Online]. Available: <https://www.nice.org.uk> (downloaded 2026, June. 11)
- [10] World Health Organization. (2020). *Diagnosis and Management of Type 2 Diabetes* [Online]. Available: <https://www.who.int> (downloaded 2026, June. 11)
- [11] World Health Organization. (2021). *Guideline for the pharmacological treatment of hypertension in adults* [Online]. Available: <https://www.who.int> (downloaded 2026, June. 11)
- [12] d4data. (2022). *biomedical-ner-all* [Online]. Available: <https://huggingface.co/d4data/biomedical-ner-all> (downloaded 2026, July. 1)
- [13] M. Neumann, D. King, I. Beltagy, and W. Ammar, "ScispaCy: Fast and Robust Models for Biomedical Natural Language Processing," *Proc. of the 18th BioNLP Workshop and Shared Task*, pp. 319-327, 2019.
- [14] Gemma Team, Google DeepMind. (2024). *Gemma: Open Models Based on Gemini Research and Technology* [Online]. Available: <https://arxiv.org/abs/2403.08295> (downloaded 2026, July. 10)